



ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΙΑΣ

Σχολή Τεχνολογίας

Τμήμα Ψηφιακών Συστημάτων

Ανίχνευση Ασθένειας με Μηχανική Μάθηση

ΠΤΥΧΙΑΚΗ ΕΡΓΑΣΙΑ

Παναγιώτης Ηλίας Τσομπάνογλου 3120140

Χρήστος Τσούτσας 3120144

Επιβλέπων: Φ. Κόκκορας, Επικ. Καθηγητής

ΛΑΡΙΣΑ, Ιούνιος 2025



UNIVERSITY OF THESSALY

School of Technology

Digital Systems Department

Disease Detection with Machine Learning

BACHELOR THESIS

Panagiotis Ilias Tsompanoglou 3120140

Christos Tsoutsas 3120144

Supervisor: *F. Kokkoras, Assit. Professor*

LARISSA, Jun-2025

Υπεύθυνη Δήλωση περί Ακαδημαϊκής Δεοντολογίας και Πνευματικών Δικαιωμάτων

Με πλήρη επίγνωση των συνεπειών του νόμου περί πνευματικών δικαιωμάτων, δηλώνω ρητά ότι η παρούσα πτυχιακή εργασία, καθώς και τα ηλεκτρονικά αρχεία και πηγαίοι κώδικες που αναπτύχθηκαν ή τροποποιήθηκαν στα πλαίσια αυτής της εργασίας, αποτελεί αποκλειστικά προϊόν προσωπικής μου εργασίας, δεν προσβάλλει κάθε μορφής δικαιώματα διανοητικής ιδιοκτησίας, προσωπικότητας και προσωπικών δεδομένων τρίτων, δεν περιέχει έργα/εισφορές τρίτων για τα οποία απαιτείται άδεια των δημιουργών/δικαιούχων και δεν είναι προϊόν μερικής ή ολικής αντιγραφής, οι πηγές δε που χρησιμοποιήθηκαν περιορίζονται στις βιβλιογραφικές αναφορές και μόνον, και πληρούν τους κανόνες της επιστημονικής παράθεσης. Τα σημεία όπου έχω χρησιμοποιήσει ιδέες, κείμενο, αρχεία ή/και πηγές άλλων συγγραφέων, αναφέρονται ευδιάκριτα στο κείμενο με την κατάλληλη παραπομπή και η σχετική αναφορά περιλαμβάνεται στο τμήμα των βιβλιογραφικών αναφορών με πλήρη περιγραφή.

Αναλαμβάνω πλήρως, ατομικά και προσωπικά, όλες τις νομικές και διοικητικές συνέπειες που δύναται να προκύψουν στην περίπτωση κατά την οποία αποδειχθεί, διαχρονικά, ότι η εργασία αυτή ή τμήμα της δεν μου ανήκει διότι είναι προϊόν λογοκλοπής.

Ο/Η Δηλών/ούσα

(Υπογραφή)

Ονοματεπώνυμο Φοιτητή/-ήτριας

Ημερομηνία

Εγκρίνεται από την Επιτροπή Εξέτασης:

Επιβλέπων/πrouσα

Φώτιος Κόκκορας

Επικ. Καθηγητής, επιβλέπων

Τμήμα Ψηφιακών Συστημάτων, Πανεπιστήμιο Θεσσαλίας

Μέλος

Μέλος

Ημερομηνία έγκρισης: dd-mm-yyyy

Περίληψη

Η χρήση Τεχνητής Νοημοσύνης στη ιατρική έχει βοηθήσει σημαντικά στη διάγνωση με βάση τις διάφορες απεικονίσεις (ακτινογραφίες, τομογραφίες, κτλ).

Η παρούσα διατριβή αποσκοπεί στη σύγκριση τεσσάρων διαφορετικών αρχιτεκτονικών βαθιάς μάθησης, δηλαδή των U-Net, Vision Transformer (ViT), DeepMedic και TransBTS, με βάση την τμηματοποίηση τρισδιάστατων (3D) όγκων εγκεφάλου χρησιμοποιώντας το σύνολο δεδομένων BraTS που αποτελεί σημείο αναφοράς. Μέσω εκτεταμένης βιβλιογραφικής ανασκόπησης, η παρούσα έρευνα αναδεικνύει βασικές κλινικές απαιτήσεις, όπως η ακριβής οριοθέτηση του όγκου και η δυνατότητα εφικτής ενσωμάτωσης των μοντέλων στην κλινική ροή εργασίας, μαζί με τις τρέχουσες τεχνικές προκλήσεις, όπως η πολυπλοκότητα της τρισδιάστατης απεικόνισης, η ετερογένεια των δεδομένων και η ερμηνευσιμότητα. Η αξιολόγησή τους πραγματοποιείται απουσία μεθόδων προεπεξεργασίας ή επαύξης των δεδομένων, καθιστώντας έτσι δυνατή τη διερεύνηση της εγγενούς ευρωστίας τους και της ικανότητάς τους να γενικεύονται υπό περιορισμένες συνθήκες.

Τα αποτελέσματα δείχνουν σημαντικές διαφορές μεταξύ των διαφόρων αρχιτεκτονικών- τα μοντέλα U-Net και TransBTS έχουν σταθερά καλές επιδόσεις ακόμη και σε αυτές τις περιορισμένες συνθήκες, ενώ το μοντέλο ViT είναι ιδιαίτερα ισχυρό στην κωδικοποίηση παγκόσμιας χωρικής πληροφορίας. Το DeepMedic έχει σημαντικά χειρότερες επιδόσεις, δείχνοντας αυξημένη εξάρτηση από τις τεχνικές επαύξης δεδομένων. Τα αποτελέσματα υπογραμμίζουν την ύψιστη σημασία της επιλογής κατάλληλων αρχιτεκτονικών σε συνδυασμό με την προσεκτική προετοιμασία και επεξεργασία των δεδομένων για την επίτευξη κλινικά αξιόπιστων αποτελεσμάτων. Ιδιαίτερη έμφαση δίνεται στην ανάγκη ερμηνευσιμότητας των μοντέλων, με εργαλεία όπως το Grad-CAM, για την ενίσχυση της εμπιστοσύνης των κλινικών εμπειρογνομόνων και τη διευκόλυνση της ενσωμάτωσης της τεχνητής νοημοσύνης στην καθημερινή κλινική ρουτίνα. Παράλληλα, η μελέτη προτείνει συγκεκριμένες κατευθύνσεις για τη μελλοντική έρευνα με στόχο τη βιώσιμη και αποτελεσματική ενσωμάτωση της τεχνητής νοημοσύνης σε κλινικά περιβάλλοντα.

Abstract

The incorporation of Artificial Intelligence (AI) in medical imaging has significantly fostered progress in neuroimaging, thereby facilitating the precision and individualization of brain tumor diagnosis and treatment. This dissertation aims to compare four various deep learning architectures, i.e., U-Net, Vision Transformer (ViT), DeepMedic, and TransBTS, based on three-dimensional (3D) brain tumor segmentation using the benchmarked BraTS dataset. Through extensive literature review, this research highlights key clinical requirements, such as precise tumor delineation and the possibility of feasible integration of models into clinical workflow, along with current technical challenges, such as the complexity of 3D imaging, data heterogeneity, and interpretability. Their assessment is carried out in the absence of preprocessing methods or data augmentation, thus making it possible to investigate their inherent robustness and ability to generalize under constrained processing circumstances. The results show significant differences between the different architectures; the U-Net and TransBTS models perform consistently well even in these limited settings, whereas the ViT model is particularly strong at encoding global spatial information. DeepMedic performs significantly worse, showing an increased dependency on data augmentation techniques. The results stress the paramount importance of selecting suitable architectures along with careful data preparation and processing to arrive at clinically trustworthy outcomes. Specific emphasis is laid on the need for model interpretability, with tools such as Grad-CAM, to boost the confidence of clinical experts and facilitate the embedding of artificial intelligence in daily clinical routine. Meanwhile, the study suggests specific directions for future research targeting the sustainable and efficient integration of AI into clinical settings.

Ευχαριστίες

Θα θέλαμε να εκφράσουμε τις θερμές ευχαριστίες μας στον καθηγητή μας, κ. Φώτιο Κόκορα, για την πολύτιμη υποστήριξη και καθοδήγησή του καθ' όλη τη διάρκεια της πτυχιακής μας εργασίας.

Ευχαριστούμε επίσης τον κ. Νικόλα Παπαγεωργίου για τη συνεχή ανατροφοδότηση κατά τη διάρκεια της έρευνας και της συγγραφής των ιατρικών ενοτήτων - οι γνώσεις και η εμπειρία του ήταν ιδιαίτερα σημαντικές για την κατανόηση των σχετικών εννοιών.

Στη συνέχεια, θα θέλαμε να ευχαριστήσουμε τον κ. Χρήστο Τσαλίδη και τον κ. Γρηγόρη Σιναπάλο για τη βοήθειά τους στην επαλήθευση των τεχνολογικών πληροφοριών που παρουσιάζονται στην παρούσα εργασία.

Τέλος, ευχαριστούμε το προσωπικό του Τμήματος Ψηφιακών Συστημάτων του Πανεπιστημίου Θεσσαλίας και τις οικογένειές μας για τη διαρκή υποστήριξή τους σε όλη αυτή τη διαδρομή.

Τσομπάνογλου Παναγιώτης Ηλίας

Χρήστος Τσούτσας

15/6/2025

Περιεχόμενα

ΠΕΡΙΛΗΨΗ.....	VII
ABSTRACT	IX
ΕΥΧΑΡΙΣΤΙΕΣ.....	X
ΠΕΡΙΕΧΟΜΕΝΑ.....	XI
1 ΕΙΣΑΓΩΓΗ.....	1
2 ΒΙΒΛΙΟΓΡΑΦΙΚΗ ΑΝΑΣΚΟΠΗΣΗ.....	3
2.1 ΚΛΙΝΙΚΗ ΠΛΕΥΡΑ ΤΟΥ ΠΡΟΒΛΗΜΑΤΟΣ	4
2.1.1 Ενσωμάτωση Μοντέλων AI στην Κλινική Πρακτική.....	6
2.1.2 Εμπόδια και Προκλήσεις στην Εφαρμογή της AI στην Ιατρική.....	8
2.2 ΤΕΧΝΙΚΗ ΠΛΕΥΡΑ ΤΟΥ ΠΡΟΒΛΗΜΑΤΟΣ.....	10
2.2.1 Τεχνικές Τρισδιάστατης Τμηματοποίησης.....	11
2.2.2 Αρχιτεκτονικές Μοντέλων για 3D Δεδομένα.....	12
2.3 ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΚΑΙ ΕΠΑΥΞΗΣΗ ΔΕΔΟΜΕΝΩΝ.....	14
2.3.1 Προετοιμασία Δεδομένων (Data Preprocessing).....	15
2.3.2 Επαύξηση Δεδομένων (Data Augmentation)	16
2.4 ΤΕΧΝΙΚΕΣ ΕΡΜΗΝΕΥΣΙΜΟΤΗΤΑΣ	17
2.5 ΜΕΛΛΟΝΤΙΚΕΣ ΤΑΣΕΙΣ ΣΤΗΝ ΤΡΙΣΔΙΑΣΤΑΤΗ ΤΜΗΜΑΤΟΠΟΙΗΣΗ	19
2.6 ΣΥΝΟΨΗ ΤΗΣ ΒΙΒΛΙΟΓΡΑΦΙΚΗΣ ΑΝΑΣΚΟΠΗΣΗΣ	22
3 ΜΕΘΟΔΟΛΟΓΙΑ.....	23
3.1 ΔΕΔΟΜΕΝΑ.....	24
3.1.1 Περιγραφή του Συνόλου Δεδομένων BraTS.....	24
3.2 ΜΟΝΤΕΛΑ.....	25
3.2.1 Επιλογή Μοντέλων προς Σύγκριση.....	25
3.2.2 Περιγραφή των Αρχιτεκτονικών.....	26
3.2.3 Προετοιμασία Δεδομένων.....	28
4 ΑΠΟΤΕΛΕΣΜΑΤΑ.....	51
4.1 ΑΞΙΟΛΟΓΗΣΗ ΚΑΙ ΣΥΓΚΡΙΣΗ ΤΩΝ ΜΟΝΤΕΛΩΝ	51
4.1.1 UNET:.....	52
4.1.2 ViT:.....	55
4.1.3 DeepMedic:.....	58
4.1.4 TransBTS:.....	60
4.2 ΣΥΓΚΡΙΤΙΚΗ ΑΝΑΛΥΣΗ ΟΛΩΝ ΤΩΝ ΜΟΝΤΕΛΩΝ:	62
5 ΣΥΖΗΤΗΣΗ.....	65
5.1 ΑΝΑΛΥΣΗ ΤΩΝ ΕΥΡΗΜΑΤΩΝ.....	65
5.2 ΠΕΡΙΟΡΙΣΜΟΙ ΤΗΣ ΜΕΛΕΤΗΣ.....	66
5.3 ΚΛΙΝΙΚΗ ΣΗΜΑΣΙΑ ΤΩΝ ΑΠΟΤΕΛΕΣΜΑΤΩΝ	67
6 ΣΥΜΠΕΡΑΣΜΑΤΑ.....	69
ΒΙΒΛΙΟΓΡΑΦΙΑ.....	71

1 Εισαγωγή

Η εφαρμογή της τεχνητής νοημοσύνης (AI) στην ιατρική απεικόνιση έχει μεταμορφώσει το πεδίο της νευροαπεικόνισης, ανοίγοντας νέους ορίζοντες για την εξατομικευμένη διάγνωση και θεραπεία εγκεφαλικών όγκων. Η ακριβής τρισδιάστατη τμηματοποίηση των εγκεφαλικών όγκων αποτελεί κρίσιμο εργαλείο για τον προσδιορισμό της μορφολογίας των όγκων, την παρακολούθηση της εξέλιξης της νόσου και την εφαρμογή εξατομικευμένων θεραπευτικών πρωτοκόλλων [58], [59]. Παρά τις σημαντικές προόδους, οι παραδοσιακές μέθοδοι αντιμετωπίζουν σοβαρές προκλήσεις λόγω της πολυπλοκότητας των 3D ιατρικών εικόνων και της μεταβλητότητας των δεδομένων, γεγονός που απαιτεί την υιοθέτηση σύγχρονων τεχνικών βαθιάς μάθησης και υβριδικών αρχιτεκτονικών για την επίτευξη υψηλής ακρίβειας και γενίκευσης [49], [52].

Σε κλινικό επίπεδο, η ακριβής οριοθέτηση τόσο των πρωτογενών όσο και των δευτερογενών όγκων είναι ουσιώδης για τη σωστή διάγνωση και την επιλογή της κατάλληλης θεραπείας. Η ποικιλομορφία στις μορφολογικές και μοριακές ιδιότητες των όγκων επηρεάζει κρίσιμα παράγοντες όπως η ενδοκράνια πίεση και οι γνωστικές λειτουργίες, καθιστώντας αναγκαία την ανάπτυξη εξειδικευμένων τεχνικών ανάλυσης 3D δεδομένων για την απόδοση μιας ολοκληρωμένης εικόνας της παθολογίας.

Οι σύγχρονες μέθοδοι AI, ιδιαίτερα εκείνες που βασίζονται σε συνελκτικά νευρωνικά δίκτυα (CNN) και σε υβριδικές προσεγγίσεις που συνδυάζουν CNNs με μοντέλα μετασχηματιστών, έχουν αποδείξει την ικανότητά τους να ανιχνεύουν και να τμηματοποιούν εγκεφαλικές ανωμαλίες με υψηλή ακρίβεια. Επιπρόσθετα, οι τεχνικές προεπεξεργασίας και επαύξησης των δεδομένων συμβάλλουν στη βελτίωση της ποιότητας των εικόνων, διευκολύνοντας την εκπαίδευση των μοντέλων [16]. Παράλληλα, η ανάπτυξη μεθοδολογιών για την εξήγηση της λήψης αποφάσεων (εξηγήσιμη AI) αποτελεί βασικό παράγοντα για τη διαφάνεια και την εμπιστοσύνη των χρηστών, γεγονός που είναι κρίσιμο για την ενσωμάτωση των συστημάτων AI στην κλινική πρακτική.

Η παρούσα εργασία στοχεύει στην ολοκληρωμένη αξιολόγηση τεσσάρων διαφορετικών αρχιτεκτονικών μοντέλων για την τρισδιάστατη τμηματοποίηση εγκεφαλικών όγκων, χρησιμοποιώντας το σύνολο δεδομένων BraTS ως βασικό δείγμα. Στόχος είναι, πρώτον, να ανασκοπηθούν οι κλινικές και τεχνολογικές προκλήσεις που αντιμετωπίζουν

οι εφαρμογές AI στην ιατρική απεικόνιση, και δεύτερον, να επισημανθεί η σημασία της εξηγήσιμης AI για τη βελτίωση της διαφάνειας και της εμπιστοσύνης στα συστήματα. Τέλος, η δοκιμή των μοντέλων σε ένα πλαίσιο χωρίς την εφαρμογή τεχνικών επαύξησης δεδομένων ή εξηγήσιμων μεθοδολογιών (όπως το Grad-CAM) θα προσφέρει μια αξιολόγηση της τρέχουσας κατάστασης της τεχνολογίας, παρέχοντας ένα σημείο αναφοράς για μελλοντικές βελτιώσεις.

Η δομή της εργασίας είναι η εξής:

- Στο Κεφάλαιο 2, παρουσιάζεται μια λεπτομερής βιβλιογραφική ανασκόπηση των κλινικών αναγκών και των τεχνολογικών προκλήσεων, καθώς και η σημασία της εξηγήσιμης AI στην ιατρική απεικόνιση.
- Στο Κεφάλαιο 3, περιγράφονται λεπτομερώς τα δεδομένα, οι διαδικασίες προεπεξεργασίας και οι επιλεγμένες αρχιτεκτονικές μοντέλων, μαζί με τα κριτήρια αξιολόγησης.
- Στο Κεφάλαιο 4, παρουσιάζονται τα πειραματικά αποτελέσματα των δοκιμών των μοντέλων.
- Στο Κεφάλαιο 5, γίνεται εμπεριστατωμένη συζήτηση των ευρημάτων, με ανάλυση των δυνατών σημείων, των περιορισμών και των προοπτικών για μελλοντικές βελτιώσεις.

Συνολικά, η εργασία αυτή συνδυάζει θεωρητικές και εμπειρικές προσεγγίσεις για να αναδείξει τη συμβολή της AI στην ιατρική διάγνωση και θεραπεία. Μέσω της ολοκληρωμένης παρουσίασης των δεδομένων και της ανάλυσης των μοντέλων, επιδιώκεται η ανάπτυξη αξιόπιστων και διαφανών διαγνωστικών εργαλείων που θα υποστηρίξουν την εξατομικευμένη ιατρική πρακτική, ενώ θέτει τα θεμέλια για μελλοντική έρευνα στον τομέα της εξηγήσιμης AI.

2 Βιβλιογραφική Ανασκόπηση

Η τρισδιάστατη τμηματοποίηση όγκων εγκεφάλου αποτελεί ένα από τα πλέον πιο κρίσιμα και δραστήρια πεδία έρευνας στην ανάλυση ιατρικών απεικονίσεων με την χρήση τεχνητής νοημοσύνης (AI). Η δυνατότητα ακριβούς αναγνώρισης και οριοθέτησης του όγκου σε 3D διαστάσεις είναι καθοριστική για τη διάγνωση, το σχεδιασμό εξατομικευμένων θεραπευτικών στρατηγικών και την παρακολούθηση της εξέλιξης ή υποτροπής της νόσου.[1] Παρά τις σημαντικές προόδους που έχουν σημειωθεί τα τελευταία χρόνια, η ενσωμάτωση των μοντέλων τεχνητής νοημοσύνης στην κλινική πρακτική αντιμετωπίζει ακόμα πολλαπλές προκλήσεις, εξαιτίας τεχνικών, κλινικών και ρυθμιστικών προκλήσεων.[2]

Στο πλαίσιο της παρούσας βιβλιογραφικής ανασκόπησης θα εξετάσουμε το κλινικό υπόβαθρο του προβλήματος, επισημαίνοντας πώς η AI μπορεί να ενσωματωθεί στην κλινική ροή εργασίας, καθώς και τα εμπόδια που δυσχεραίνουν την ευρεία αποδοχή της από την ιατρική κοινότητα. Στη συνέχεια, θα προσεγγίσουμε την τεχνική πλευρά του προβλήματος. Εκεί θα παρουσιάσουμε τις σύγχρονες μεθόδους τρισδιάστατης τμηματοποίησης και τις σχετικές αρχιτεκτονικές μοντέλων. Επιπλέον, θα αναλύσουμε τις τεχνικές προεπεξεργασίας και επαύξησης δεδομένων, καθώς και τις προκλήσεις που ανακύπτουν κατά την επεξεργασία 3D ιατρικών εικόνων.




Figure 1

2.1 Κλινική Πλευρά του Προβλήματος

Η ανάπτυξη εγκεφαλικών όγκων αποτελεί ένα εξαιρετικά σύνθετο και κρίσιμης σημασίας ζήτημα για την κλινική πράξη, καθώς η παρουσία νεοπλασματικών σχηματισμών στον εγκέφαλο επηρεάζει άμεσα τη φυσιολογία και τη λειτουργικότητα του κεντρικού νευρικού συστήματος. Η πολυπλοκότητα αυτών, απορρέει από την ποικιλομορφία τους, καθώς διακρίνονται σε πρωτογενείς όγκους, οι οποίοι προκύπτουν από τον εγκεφαλικό ιστό (π.χ. γλοιώματα, αστροκυτώματα, ολιγοδενδρογλοιώματα), και δευτερογενείς ή μεταστατικούς, οι οποίοι προέρχονται από τη διασπορά καρκινικών κυττάρων από άλλους ιστούς ή όργανα, όπως ο πνεύμονας και ο μαστός [1]. Η διάκριση μεταξύ καλοθών και κακοθών όγκων βασίζεται σε ιστολογικά και μοριακά χαρακτηριστικά, που καθορίζουν τη βιολογική συμπεριφορά, την πρόγνωση και τη θεραπευτική στρατηγική της νόσου. Επομένως, ιδιαίτερη σημασία αποκτά η ανίχνευση γενετικών και επιγενετικών μεταλλάξεων, οι οποίες αποτελούν καίριους προγνωστικούς δείκτες και καθοδηγούν εξατομικευμένες θεραπευτικές προσεγγίσεις [2], ενώ η επίδραση περιβαλλοντικών παραγόντων δεν πρέπει να λησμονείται από τους θεράποντες.

Η επίδραση των εγκεφαλικών όγκων στη λειτουργία του εγκεφάλου προκαλεί πολλαπλά και πολύπλοκα κλινικά ζητήματα. Οι επιπτώσεις των όγκων ποικίλλουν ανάλογα με τη χωροταξική τους εντόπιση, το μέγεθος, τον ρυθμό ανάπτυξης και την πιθανότητα διήθησης γειτονικών ιστών. Δεδομένου ότι ο εγκέφαλος περιβάλλεται από τον περιορισμένο ανατομικό χώρο του κρανίου, μια κλειστή κοιλότητα, ακόμη και μικρές νεοπλασματικές αλλοιώσεις μπορούν να προκαλέσουν αύξηση της ενδοκράνιας πίεσης, οδηγώντας σε σοβαρές νευρολογικές διαταραχές. Οι συνέπειες οι οποίες μπορεί να δημιουργηθούν από αυτές τις διαταραχές είναι προβλήματα στη μνήμη, τις εκτελεστικές λειτουργίες, την οπτικοχωρική αντίληψη, στη συναισθηματική ισορροπία αλλά και να οδηγήσει σε απώλεια προσοχής[3], καθώς επίσης μπορούν να παρατηρηθούν και ψυχιατρικές διαταραχές. Παράλληλα, οι θεραπευτικές παρεμβάσεις, όπως η χειρουργική αφαίρεση, η ακτινοθεραπεία και η χημειοθεραπεία, επηρεάζουν τη γνωστική λειτουργία τόσο βραχυπρόθεσμα όσο και μακροπρόθεσμα. Ενδεικτικά, η χειρουργική επέμβαση μπορεί να προκαλέσει προσωρινή γνωστική δυσλειτουργία (και γενικότερη έκπτωση νευρολογικών λειτουργιών), ενώ η ακτινοθεραπεία έχει συνδεθεί με χρόνιες γνωστικές επιπτώσεις, ιδίως σε περιπτώσεις παρατεταμένης έκθεσης [4][2].

Η διαγνωστική προσέγγιση των εγκεφαλικών όγκων βασίζεται πρωτίστως στη μαγνητική τομογραφία (MRI), η οποία θεωρείται η μέθοδος εκλογής για την απεικόνιση

της εγκεφαλικής ανατομίας και την ανίχνευση παθολογικών εστιών. Η υψηλή ευκρίνεια της MRI επιτρέπει την ακριβή αξιολόγηση του μεγέθους, της θέσης και της πιθανής διήθησης του όγκου στους παρακείμενους ιστούς [6]. Παράλληλα, το γεγονός ότι με την παρούσα εξέταση ο ασθενής δεν επιβαρύνεται ακτινολογικά, δύναται η πιθανότητα επανάληψης της χωρίς ενδοιασμό. Επιπλέον, προηγμένες τεχνικές, όπως η φασματοσκοπία μαγνητικού συντονισμού (MRS) και η απεικόνιση διάχυσης (DTI), προσφέρουν σημαντικές πληροφορίες για τη μεταβολική δραστηριότητα και τη μικροδομή των νεοπλασματικών ιστών. Η ιστολογική ανάλυση μέσω βιοψίας εξακολουθεί να αποτελεί το «χρυσό πρότυπο» για την οριστική διάγνωση και την τυποποίηση των όγκων, ενώ η μοριακή τυποποίηση καθορίζει την επιλογή στοχευμένων θεραπειών [2][1] .

Η θεραπευτική προσέγγιση των εγκεφαλικών όγκων, είναι εξατομικευμένη και εξαρτάται από παράγοντες όπως ο ιστολογικός τύπος, το μέγεθος, η εντόπιση, η μοριακή υπογραφή του όγκου, καθώς και η γενική κατάσταση του ασθενούς. Η χειρουργική επέμβαση, αποτελεί τη θεραπεία εκλογής σε περιπτώσεις όπου είναι εφικτή η πλήρης ή μερική αφαίρεση του όγκου. Η ακτινοθεραπεία εφαρμόζεται είτε ως επικουρική είτε ως εναλλακτική θεραπεία, ιδίως σε περιπτώσεις επιθετικών ή μη εγχειρήσιμων όγκων [2][3][5]. Παρά τις σημαντικές προόδους στη χειρουργική και ακτινοθεραπευτική τεχνολογία, η πρόγνωση παραμένει επιφυλακτική, ιδιαίτερα για ασθενείς με επιθετικούς όγκους, όπως το γλοιοβλάστωμα, όπου τα ποσοστά επιβίωσης παραμένουν χαμηλά. Η ακριβής, τρισδιάστατη τμηματοποίηση των εγκεφαλικών όγκων μέσω MRI είναι απαραίτητη για τη διαμόρφωση αποτελεσματικών θεραπευτικών στρατηγικών. Η δυνατότητα εντοπισμού, χαρακτηρισμού και ποσοτικοποίησης του όγκου με ακρίβεια υποστηρίζει τη λήψη τεκμηριωμένων κλινικών αποφάσεων, επιτρέπει τη συγκριτική αξιολόγηση διαφορετικών θεραπευτικών προσεγγίσεων και διευκολύνει την παρακολούθηση της πορείας της νόσου με αντικειμενικό τρόπο.

Στο πλαίσιο αυτό, η τεχνητή νοημοσύνη (AI) αναδεικνύεται ως ένα εξαιρετικά υποσχόμενο εργαλείο για την ενίσχυση της διαγνωστικής και θεραπευτικής διαδικασίας. Η αυτοματοποιημένη ανάλυση μεγάλων και ετερογενών συνόλων δεδομένων επιτρέπει την ταχύτερη και ακριβέστερη εκτίμηση απεικονιστικών, κλινικών και μοριακών χαρακτηριστικών των όγκων. Οι αλγόριθμοι μηχανικής μάθησης, ιδίως αυτοί της βαθιάς μάθησης, επιδεικνύουν εξαιρετικές επιδόσεις στον εντοπισμό και την ταξινόμηση νεοπλασματικών σχηματισμών, συμβάλλοντας στη βελτίωση της ακρίβειας και της ταχύτητας των διαγνωστικών αποφάσεων. Με αυτόν τον τρόπο, καθίσταται δυνατή η επιλογή εξατο-

μικευμένων θεραπευτικών πρωτοκόλλων, προσαρμοσμένων στις ιδιαιτερότητες κάθε ασθενούς, ενισχύοντας την αποτελεσματικότητα της κλινικής φροντίδας και προάγοντας τη σύγχρονη εξατομικευμένη ιατρική [9].

2.1.1 Ενσωμάτωση Μοντέλων AI στην Κλινική Πρακτική

Η ενσωμάτωση της Τεχνητής Νοημοσύνης (AI) στην κλινική πρακτική συνιστά μία εκ των πλέον υποσχόμενων καινοτομιών στη σύγχρονη ιατρική, προσφέροντας πρωτοφανείς δυνατότητες για την ενίσχυση της διαγνωστικής ακρίβειας και τη βελτιστοποίηση των θεραπευτικών στρατηγικών. Στον τομέα της ακτινοδιαγνωστικής και της νευροογκολογίας, τα συστήματα AI έχουν ήδη υιοθετηθεί για την ανάλυση απεικονιστικών δεδομένων, ιδίως από μαγνητικές τομογραφίες (MRI) και αξονικές τομογραφίες (CT), εξασφαλίζοντας υψηλή ακρίβεια, ταχύτητα και αξιοπιστία στη διαγνωστική διαδικασία. Ενδεικτικό παράδειγμα αποτελούν οι αλγόριθμοι βαθιάς μάθησης (deep learning), οι οποίοι έχουν αποδείξει εξαιρετική ικανότητα στην αυτόματη ανίχνευση και ταξινόμηση εγκεφαλικών όγκων, συμβάλλοντας έτσι στη βελτίωση της κλινικής έκβασης των ασθενών [1], [3], [9]. Επιπρόσθετα, η αυτοματοποίηση της ανάλυσης ιατρικών εικόνων μέσω AI διασφαλίζει τη συνοχή και την επαναληψιμότητα των διαγνώσεων, ενώ η τυποποίηση των διαδικασιών ενισχύει την προγνωστική ισχύ των συστημάτων, διευκολύνοντας την εφαρμογή εξατομικευμένων θεραπευτικών πλάνων [10].

Η αξιοποίηση της AI στον τομέα της νευροαπεικόνισης έχει συμβάλει αποφασιστικά στη βελτίωση της ταχύτητας και της ακρίβειας των διαγνωστικών αποφάσεων. Η δυνατότητα ανάλυσης πολύπλοκων και μεγάλου όγκου δεδομένων σε σύντομο χρονικό διάστημα διευκολύνει τη λήψη κλινικών αποφάσεων σε πραγματικό χρόνο, γεγονός που είναι καίριο για τη διαχείριση επειγόντων περιστατικών (triage). Παράλληλα, σύγχρονες τεχνικές οπτικοποίησης, όπως η Grad-CAM (Gradient-weighted Class Activation Mapping), επιτρέπουν την ανάδειξη κρίσιμων περιοχών ενδιαφέροντος στις ιατρικές εικόνες, ενισχύοντας τη διαφάνεια και την ερμηνευσιμότητα των αποφάσεων που λαμβάνουν τα συστήματα AI. Αυτό το χαρακτηριστικό είναι ιδιαίτερα σημαντικό, καθώς ενισχύει την εμπιστοσύνη των κλινικών ιατρών στα εργαλεία AI και προάγει τη συνεργασία ανθρώπου-μηχανής στη λήψη τεκμηριωμένων και επιστημονικά ορθών (Lege artis) κλινικών αποφάσεων [6], [9].

Επιπλέον, αναδεικνύεται η σημασία της εφαρμογής αλγορίθμων συνεχούς μάθησης (continuous learning) στην ακτινολογία, οι οποίοι παρέχουν τη δυνατότητα δυναμικής

προσαρμογής των μοντέλων ΑΙ στις διαρκώς εξελισσόμενες κλινικές απαιτήσεις και στις μεταβαλλόμενες συνθήκες. Η διαδικασία αυτή της συνεχούς ανατροφοδότησης επιτρέπει τη βελτίωση της διαγνωστικής ακρίβειας και τη μείωση των σφαλμάτων, ενισχύοντας έτσι την ασφάλεια των ασθενών. Ωστόσο, για την επιτυχή ενσωμάτωση των συστημάτων ΑΙ στην καθημερινή κλινική πρακτική, απαιτείται η διεπιστημονική συνεργασία μεταξύ ειδικών τεχνητής νοημοσύνης και επαγγελματιών υγείας, καθώς και η συστηματική εκπαίδευση του ιατρικονοσηλευτικού προσωπικού. Η εκπαίδευση αυτή, είναι καίριας σημασίας, ώστε οι επαγγελματίες να κατανοήσουν τις δυνατότητες, τους περιορισμούς και τον ορθό τρόπο χρήσης των συστημάτων ΑΙ. [11], [12].

Η πλήρης ενσωμάτωση της ΑΙ στην κλινική πράξη αναμένεται να προσφέρει πολλά πλά οφέλη, όπως η μείωση του χρόνου διάγνωσης, η αύξηση της διαγνωστικής ακρίβειας και η βελτιστοποίηση της παρεχόμενης φροντίδας. Παρά τις προκλήσεις, η τεχνολογία αυτή διανοίγει νέους ορίζοντες για την ιατρική επιστήμη, καθιστώντας δυνατή την παροχή εξατομικευμένης φροντίδας υψηλής ποιότητας, με ταυτόχρονη βελτίωση της αποτελεσματικότητας των θεραπευτικών παρεμβάσεων και της κλινικής έκβασης των ασθενών [8].




Figure 2 [12]

2.1.2 Εμπόδια και Προκλήσεις στην Εφαρμογή της ΑΙ στην Ιατρική

Η ενσωμάτωση της Τεχνητής Νοημοσύνης (ΑΙ) στην ιατρική πρακτική συνεχίζει να αντιμετωπίζει μία σειρά πολύπλοκων προκλήσεων, οι οποίες χαρακτηρίζονται από πολυεπίπεδο και πολυπαραγοντικό χαρακτήρα, καλύπτοντας ζητήματα ηθικής, τεχνικής φύσεως, ρυθμιστικού πλαισίου και κοινωνικοπολιτισμικών αντιλήψεων. Η εφαρμογή της ΑΙ σε κλινικό επίπεδο απαιτεί την πρόσβαση σε μεγάλης κλίμακας και συχνά ευαίσθητα δεδομένα ασθενών, γεγονός που εγείρει σοβαρές ανησυχίες σχετικά με τη διασφάλιση της ιδιωτικότητας και την ορθή χρήση των δεδομένων. Η διαχείριση αυτών των προκλήσεων είναι ζωτικής σημασίας για την ευρεία και ασφαλή υιοθέτηση των τεχνολογιών ΑΙ στη σύγχρονη ιατρική πρακτική [14], [15]. Παρά το γεγονός ότι πρακτικές όπως η ανωνυμοποίηση και η λήψη συνειδητής συγκατάθεσης συμβάλλουν στη μείωση του κινδύνου παραβίασης της ιδιωτικότητας, δεν εξαλείφουν πλήρως τον κίνδυνο κακόβουλης εκμετάλλευσης των δεδομένων. Επιπλέον, η ύπαρξη μεροληπτικών δεδομένων στις βάσεις δεδομένων μπορεί να οδηγήσει σε ανακρίβειες, άνισες ή προκατειλημμένες αποφάσεις, προκαλώντας σοβαρά ηθικά διλήμματα τόσο για τους κλινικούς ιατρούς όσο και για τους δημιουργούς των αλγορίθμων [11].

Σε τεχνικό επίπεδο, μία από τις πλέον σημαντικές προκλήσεις αφορά την περιορισμένη ανθεκτικότητα (robustness) των αλγορίθμων σε ετερογενή κλινικά περιβάλλοντα. Οι αλγόριθμοι συχνά αποτυγχάνουν να διατηρήσουν υψηλή απόδοση όταν οι συνθήκες εισόδου διαφοροποιούνται από τα δεδομένα εκπαίδευσης, γεγονός που οδηγεί σε μειωμένη ακρίβεια και αξιοπιστία [7], [12]. Επιπρόσθετα, η περιορισμένη δυνατότητα ερμηνείας (explainability) των αποτελεσμάτων που παρέχουν τα συστήματα ΑΙ δυσχεραίνει την κατανόηση των αποφάσεων από τους κλινικούς επαγγελματίες, με αποτέλεσμα να μειώνεται η εμπιστοσύνη στη χρήση αυτών των εργαλείων και να παρεμποδίζεται η ευρεία ενσωμάτωσή τους στη ροή της καθημερινής κλινικής πρακτικής [9].

Ένα ακόμη κρίσιμο ζήτημα είναι η διαλειτουργικότητα (interoperability) των συστημάτων ΑΙ με τις ήδη υπάρχουσες υγειονομικές υποδομές. Η επιτυχής ενσωμάτωση λύσεων ΑΙ απαιτεί σημαντικές τεχνικές, οικονομικές και οργανωτικές επενδύσεις [9], [13]. Παράλληλα, το ασαφές νομικό και ρυθμιστικό πλαίσιο που διέπει την πιστοποίηση των συστημάτων ΑΙ και την κατανομή της ευθύνης σε περίπτωση ιατρικού σφάλματος αποτελεί τροχοπέδη για την αποδοχή και τη διάδοσή τους [8].

Επιπλέον, οι κοινωνικοπολιτισμικοί παράγοντες διαδραματίζουν καθοριστικό ρόλο στην αποδοχή των τεχνολογιών ΑΙ από τους ασθενείς και τους επαγγελματίες υγείας. Η

δυσπιστία των ασθενών απέναντι στα συστήματα AI, η οποία οφείλεται κυρίως στην απουσία ανθρώπινης αλληλεπίδρασης και στην πιθανότητα λανθασμένων διαγνώσεων, δύναται να περιορίσει τη διάδοσή τους. Παράλληλα, ορισμένοι κλινικοί επαγγελματίες προσεγγίζουν με επιφυλακτικότητα τη χρήση τέτοιων εργαλείων, εξαιτίας της αδυναμίας πλήρους κατανόησης του τρόπου με τον οποίο οι αλγόριθμοι λαμβάνουν αποφάσεις [6].

Για να αντιμετωπιστούν αυτές οι προκλήσεις, απαιτείται στοχευμένη εκπαίδευση των επαγγελματιών υγείας, διαφάνεια στις διαδικασίες λήψης αποφάσεων των αλγορίθμων και ανάπτυξη μοντέλων που παρέχουν σαφείς και κατανοητές εξηγήσεις των αποτελεσμάτων. Μόνο μέσω αυτών των δράσεων είναι δυνατή η οικοδόμηση εμπιστοσύνης αλλά και η πλήρης αξιοποίηση του δυναμικού της τεχνητής νοημοσύνης στη σύγχρονη ιατρική πρακτική [9], [13].

Παρά τις ανωτέρω προκλήσεις, η τεχνητή νοημοσύνη αναμένεται να διαδραματίσει καίριο ρόλο στη μελλοντική εξέλιξη της ιατρικής επιστήμης, προάγοντας την ακρίβεια, την ταχύτητα και την αποτελεσματικότητα της παρεχόμενης φροντίδας. Με κατάλληλη ρύθμιση και συνεχή βελτίωση, τα συστήματα AI έχουν τη δυνατότητα να αλλάξουν ριζικά το τοπίο της υγειονομικής περίθαλψης, καθιστώντας τη διάγνωση και τη θεραπεία πιο ακριβείς, αξιόπιστες και προσαρμοσμένες στις ανάγκες του κάθε ασθενούς.




Figure 3

2.2 Τεχνική Πλευρά του Προβλήματος

Η τρισδιάστατη (3D) απεικόνιση έχει αναδειχθεί σε σημαντικό εργαλείο για την ανάλυση ιατρικών δεδομένων, ιδιαίτερα όσον αφορά τους εγκεφαλικούς όγκους. Οι πληροφορίες από μαγνητικές (MRI) και αξονικές (CT) τομογραφίες παρέχουν πλούσιες χωρικές πληροφορίες, επιτρέποντας την ακριβέστερη αναπαράσταση των ανατομικών δομών και των παθολογικών μεταβολών στον εγκέφαλο. Ωστόσο, η ανάλυση αυτών των δεδομένων παρουσιάζει πολυάριθμες τεχνικές προκλήσεις, όπως η πολυπλοκότητα των εικόνων, η παρουσία θορύβου και η διαχείριση δεδομένων μεγάλου όγκου [16], [17].

Η τμηματοποίηση (segmentation) αποτελεί ένα κρίσιμο βήμα για την κατανόηση και τη διαχείριση των εγκεφαλικών όγκων, καθώς επιτρέπει τον ακριβή διαχωρισμό της παθολογικής περιοχής από τον φυσιολογικό εγκεφαλικό ιστό. Η έλευση των συνελκτικών νευρωνικών δικτύων (Convolutional Neural Networks, CNNs) και των εξειδικευμένων τρισδιάστατων μοντέλων επέτρεψε την αυτοματοποιημένη τμηματοποίηση με βελτιωμένη ακρίβεια, διευκολύνοντας έτσι τον κλινικό σχεδιασμό εξατομικευμένων θεραπειών [18], [19].

Τα τελευταία χρόνια, οι μετασχηματιστές (transformers) έχουν εισαχθεί στον τομέα της ιατρικής απεικόνισης, παρουσιάζοντας εντυπωσιακά αποτελέσματα στην τμηματοποίηση. Οι μετασχηματιστές επιτρέπουν τη σύλληψη μακροχρόνιων εξαρτήσεων (long-range dependencies) μεταξύ voxel και 3D δεδομένων, βελτιώνοντας την κατανόηση της συνολικής δομής του εγκεφάλου. Επιπλέον, η ενσωμάτωσή τους με υπάρχουσες αρχιτεκτονικές CNN έχει οδηγήσει στη δημιουργία υβριδικών μοντέλων που έχουν βελτιώσει ακόμα περισσότερο την απόδοση. [21], [22].

Στις επόμενες ενότητες, θα εξεταστούν τόσο οι θεμελιώδεις τεχνικές τρισδιάστατης τμηματοποίησης (2.2.1) όσο και οι προηγμένες αρχιτεκτονικές μοντέλων (2.2.2). Αυτή η αναλυτική προσέγγιση θα αναδείξει το πώς κλασικές μέθοδοι, σύγχρονα 3D CNNs, πολυκλιμακικές στρατηγικές, μοντέλα AutoML, καθώς και πολυτροπικές και transformer-based προσεγγίσεις, συνδυάζονται για να αντιμετωπίσουν τις προκλήσεις της 3D τμηματοποίησης και να βελτιώσουν την ακρίβεια, την ανθεκτικότητα και τη γέννηση των μοντέλων.

2.2.1 Τεχνικές Τρισδιάστατης Τμηματοποίησης

Η τρισδιάστατη τμηματοποίηση επιτρέπει τον διαχωρισμό σύνθετων δομών, όπως όγκων ή οργάνων, από το υπόβαθρο της εικόνας, αξιοποιώντας την πρόσθετη διάσταση που προσφέρουν τα 3D δεδομένα [16], [17], [18]. Σε θεμελιώδες επίπεδο, η τμηματοποίηση επιδιώκει τη μετατροπή του ιατρικού όγκου δεδομένων σε διακριτές περιοχές ενδιαφέροντος, οι οποίες μπορούν να υποβληθούν σε ποσοτικοποίηση και ανάλυση. Η τρισδιάστατη προσέγγιση αξιοποιεί πλήρως την επιπλέον διάσταση της εικόνας, προσφέροντας μια πιο ολοκληρωμένη αναπαράσταση των ανατομικών χαρακτηριστικών [23], [24]. Ωστόσο, η μετάβαση από δισδιάστατες σε τρισδιάστατες τεχνικές εισάγει πρόσθετες προκλήσεις, όπως η αυξημένη υπολογιστική επιβάρυνση και η ανάγκη διαχείρισης μεγαλύτερου εύρους χωρικών χαρακτηριστικών [17], [25].

Κλασικές Μέθοδοι

Πριν την εδραίωση της βαθιάς μάθησης, η 3D τμηματοποίηση βασιζόταν σε κλασικές μεθόδους όπως η τμηματοποίηση με βάση προτύπων (atlas-based) [26], οι active surfaces/level sets τεχνικές [27], και οι τεχνικές βασισμένες σε γράφους (graph-based) [28]. Αυτές οι προσεγγίσεις αξιοποιούσαν στατιστικές μοντελοποιήσεις και γνώση της ανατομίας, αποδίδοντας ικανοποιητικά αποτελέσματα κυρίως σε συγκεκριμένες και καλά ορισμένες περιοχές ενδιαφέροντος. Παρά ταύτα, συχνά δυσκολεύονταν με δεδομένα χαμηλής ποιότητας, θορύβου και μεγάλης ετερογένειας.

Βαθιά Μάθηση και Πολυκλιμακικές Προσεγγίσεις

Η έλευση των CNN και η καθιέρωση μοντέλων ειδικά σχεδιασμένων για την ιατρική τμηματοποίηση, όπως το U-Net και οι τρισδιάστατες παραλλαγές του, αποτέλεσαν σταθμό στο πεδίο [16], [17]. Παράλληλα, τεχνικές πολυκλιμακικής ανάλυσης επιτρέπουν την ταυτόχρονη ανάλυση λεπτομερών τοπικών χαρακτηριστικών και της συνολικής δομής της εικόνας [17]. Τεχνικές όπως η patch-based προσέγγιση [16], συνέβαλαν στην αντιμετώπιση ανισορροπίας των κλάσεων και στη μείωση της υπολογιστικής πολυπλοκότητας.

Εξελιγμένες Αρχιτεκτονικές και Dense Blocks

Η χρήση dense blocks (DenseNets) εισήχθει για να προωθήσει την επαναχρησιμοποίηση χαρακτηριστικών, μειώνοντας παράλληλα την πολυπλοκότητα του μοντέλου. Η ενσωμάτωση dense blocks σε 3D CNN βελτίωσε την ικανότητα των μοντέλων να μάθουν περίπλοκα μοτίβα σε MRI δεδομένα. Ενώ οι μετασχηματιστές, οδήγησαν σε καλύτερη

σύλληψη μακροπρόθεσμων συσχετίσεων και ανάλυση πολύπλοκων χωρικών σχέσεων σε τρεις διαστάσεις [21], [25], [29].

AutoML και Πολυτροπικές Προσεγγίσεις

Η εισαγωγή AutoML εργαλείων, όπως το nnU-Net [30], εξάλειψε σε μεγάλο βαθμό την ανάγκη χειροκίνητης ρύθμισης των υπερπαραμέτρων, επιτρέποντας στους αλγόριθμους να προσαρμόζονται αυτόματα σε διαφορετικά σύνολα δεδομένων. Παράλληλα, η πολυτροπική ανάλυση (π.χ. συνδυασμός T1, T2, Flair) [22] βελτίωσε περαιτέρω την ακρίβεια της τμηματοποίησης, αξιοποιώντας συμπληρωματικές πληροφορίες από πολλαπλές απεικονιστικές ακολουθίες.

Πρόσφατες Τάσεις και Υβριδικές Προσεγγίσεις

Πέρα από τα CNN, οι υβριδικές προσεγγίσεις που συνδυάζουν CNN με Transformers εμφανίζονται ως πολλά υποσχόμενες λύσεις, βελτιώνοντας την ανθεκτικότητα και την ικανότητα γενίκευσης σε διαφορετικά σύνολα δεδομένων [25], [29]. Επιπλέον, τεχνικές αυτοεποπτευόμενης μάθησης και μεταφοράς γνώσης (transfer learning) διευκολύνουν την ανάπτυξη μοντέλων υψηλής απόδοσης ακόμα και όταν τα διαθέσιμα δεδομένα είναι περιορισμένα. Η εφαρμογή αυτών των μεθοδολογιών, σε συνδυασμό με προσεγγίσεις όπως το contrastive learning [31], [32], συμβάλλουν στην αντιμετώπιση προβλημάτων γενίκευσης και μεροληψίας.

2.2.2 Αρχιτεκτονικές Μοντέλων για 3D Δεδομένα

Η ανάπτυξη εξειδικευμένων αρχιτεκτονικών για την ανάλυση τρισδιάστατων (3D) δεδομένων αποτελεί θεμέλιο λίθο για την επιτυχή εφαρμογή τρισδιάστατης τμηματοποίησης. Οι εν λόγω αρχιτεκτονικές καλούνται να διαχειριστούν τον υψηλό όγκο χωρικής πληροφορίας που παρέχουν οι MRI και CT απεικονίσεις, εφαρμόζοντας τις τεχνικές τμηματοποίησης που παρουσιάστηκαν προηγουμένως (βλ. Ενότητα 2.2.1) σε μοντέλα ικανά να κατανοήσουν περίπλοκες εγκεφαλικές δομές. Έτσι, η επιλογή της αρχιτεκτονικής συνδέεται άμεσα με προσεγγίσεις πολυκλιμακικής ανάλυσης, patch-based στρατηγικών, AutoML μεθόδων, καθώς και πολυτροπικών ή transformer-based τεχνικών [20], [33], [34], [35], [36], [37].

Ένα κρίσιμο ζήτημα είναι η υπολογιστική και μνημονιακή απόδοση. Τρισδιάστατα μοντέλα έχουν σημαντικά υψηλότερο φορτίο σε σχέση με 2D αντίστοιχα, καθιστώντας τη σωστή ισορροπία μεταξύ του βάθους των δικτύων, της πολυπλοκότητας των δεδο-

μένων και των διαθέσιμων πόρων (GPU μνήμη, χρόνος εκπαίδευσης) κομβικής σημασίας [25], [40].

Παράλληλα, η διασφάλιση της γενίκευσης (generalization) και της ανθεκτικότητας (robustness) επιτυγχάνεται με multiscale και patch-based στρατηγικές (αναφερθείσες στην Ενότητα 2.2.1), καθώς και πολυτροπικές αρχιτεκτονικές που αξιοποιούν πολλαπλά κανάλια πληροφορίας [20], [33], [34]. Αυτές οι λύσεις περιορίζουν την εξάρτηση από συγκεκριμένες συνθήκες σάρωσης και βελτιώνουν την απόδοση σε χαμηλής ποιότητας δεδομένα.

Παρακάτω παρουσιάζονται οι κύριες κατηγορίες αρχιτεκτονικών, συνοδευόμενες από παραδείγματα παλαιότερων και πιο σύγχρονων μοντέλων, τα οποία αντιπροσωπεύουν τη συνεχή εξέλιξη του πεδίου:

Αρχιτεκτονικές Τύπου U-Net

Το 3D U-Net εισήγαγε την επιτυχημένη λογική του U-Net στον τρισδιάστατο χώρο, προσφέροντας ισχυρή γραμμή βάσης για πολλές εφαρμογές [33]. Νεότερα μοντέλα, όπως το TransBTS, ενσωματώνουν transformers, βελτιώνοντας τη λήψη μακροπρόθεσμων χωρικών πληροφοριών [34].

Πυκνά Συνδεδεμένα Δίκτυα (DenseNets)

Τα DenseVNet και HyperDenseNet [35], [36] αξιοποιούν πυκνές συνδέσεις για καλύτερη ροή πληροφορίας και μειωμένη πολυπλοκότητα, ενώ η δυνατότητα εφαρμογής σε πολυτροπικά δεδομένα βελτιώνει την απόδοση σε δύσκολες περιπτώσεις τμηματοποίησης.

Πολυτροπικές Αρχιτεκτονικές (Multimodal Architectures)

Το MM-CNN και το MMFormer [20], [37] συνδυάζουν διαφορετικές απεικονιστικές ακολουθίες, αξιοποιώντας παράλληλα τεχνικές όπως τα transformers, ώστε να ενσωματωθούν πολλαπλές πηγές πληροφορίας, αυξάνοντας την ακρίβεια και την ανθεκτικότητα.

Αρχιτεκτονικές Βασισμένες σε Μετασχηματιστές (Transformers)

Οι Swin Transformers και το CoTr εκμεταλλεύονται την ικανότητα σύλληψης μακροπρόθεσμων χωρικών σχέσεων [22], [38]. Αυτές οι προσεγγίσεις, σε συνδυασμό με CNNs (βλ. CoTr), παρέχουν βαθύτερη κατανόηση του τρισδιάστατου χώρου, ιδιαίτερα σε απαιτητικές εφαρμογές τμηματοποίησης.

Hybrid Architectures, Εξισορρόπηση Πόρων και Γενίκευση

Το DeepMedic ενσωμάτωσε πολλαπλά μονοπάτια και CRFs για διόρθωση των προβλέψεων [17], ενώ το nnFormer εφάρμοσε την ιδέα των transformers σε συνδυασμό με CNN components, επιτυγχάνοντας κορυφαία απόδοση σε προκλήσεις όπως η τμηματοποίηση εγκεφαλικών όγκων [39].

Με αυτόν τον τρόπο, ο συνδυασμός των τεχνικών που παρουσιάστηκαν στην προηγούμενη ενότητα (2.2.1) και των εξειδικευμένων αρχιτεκτονικών που περιγράφονται εδώ, επιτρέπει την αποτελεσματική και αποδοτική αντιμετώπιση των απαιτήσεων της 3D τμηματοποίησης, προσεγγίζοντας υψηλά επίπεδα ακρίβειας, ανθεκτικότητας και αποτελεσματικής αξιοποίησης των διαθέσιμων υπολογιστικών πόρων.

2.3 Προεπεξεργασία και Επαύξηση Δεδομένων

Η ανάλυση δεδομένων και η ανάπτυξη αλγορίθμων μηχανικής και βαθιάς μάθησης εξαρτώνται σε μεγάλο βαθμό από την ποιότητα και την ποσότητα των δεδομένων. Η προεπεξεργασία και η επαύξηση δεδομένων είναι κρίσιμα στάδια στον κύκλο ζωής ενός συστήματος τεχνητής νοημοσύνης, καθώς συμβάλλουν στην αντιμετώπιση προκλήσεων όπως η ύπαρξη θορύβου, τα ελλιπή δεδομένα, η χαμηλή γενικευσιμότητα και η ανισορροπία δεδομένων [41], [42].

Συγκεκριμένα στην τρισδιάστατη (3D) τμηματοποίηση ιατρικών δεδομένων, οι προκλήσεις γίνονται ακόμη πιο έντονες λόγω του περιορισμένου όγκου διαθέσιμων δεδομένων, των περίπλοκων μορφολογικών δομών και της ανάγκης για υψηλή ακρίβεια. Η προεπεξεργασία δεδομένων περιλαμβάνει τεχνικές για τον καθαρισμό, την τυποποίηση και τη μετατροπή των δεδομένων ώστε να είναι κατάλληλα για ανάλυση. Από την άλλη πλευρά, η επαύξηση δεδομένων παρέχει τη δυνατότητα δημιουργίας μεγαλύτερων και πιο ποικιλόμορφων συνόλων δεδομένων, εξασφαλίζοντας καλύτερη γενίκευση και ανθεκτικότητα για τα μοντέλα [43], [44], [45].

Σε εφαρμογές όπως η τμηματοποίηση όγκων εγκεφάλου, αυτές οι τεχνικές έχουν αποδειχθεί θεμελιώδεις για τη βελτίωση της ακρίβειας και της αξιοπιστίας των συστημάτων τεχνητής νοημοσύνης. Επιπλέον, ο συνδυασμός προεπεξεργασίας και επαύξησης δεδομένων παρέχει τη βάση για την ανάπτυξη ισχυρών αλγορίθμων που μπορούν να εφαρμοστούν σε κρίσιμους τομείς, όπως η ιατρική διάγνωση και θεραπεία.

2.3.1 Προετοιμασία Δεδομένων (Data Preprocessing)

Η προεπεξεργασία δεδομένων αποτελεί το πρώτο βήμα για τη διασφάλιση της ποιότητας, της συνέπειας και της καταλληλότητας των δεδομένων για επεξεργασία από μοντέλα μηχανικής μάθησης.

Καθαρισμός Δεδομένων

Αντιμετώπιση Ελλιπών Δεδομένων: Οι ελλιπείς τιμές αποτελούν κοινό πρόβλημα στις ιατρικές εικόνες. Τεχνικές όπως η πολλαπλή παρεμβολή με αλυσίδες εξισώσεων (MICE) και η χρήση μέσων τιμών ή μηχανικών μοντέλων (π.χ., k-NN) έχουν εφαρμοστεί με επιτυχία για την αποκατάσταση των ελλιπών δεδομένων [41], [46].

Εξομάλυνση Θορύβου: Η απομάκρυνση του θορύβου είναι απαραίτητη για τη διατήρηση κρίσιμων λεπτομερειών στις 3D εικόνες. Τεχνικές όπως τα φίλτρα Gaussian, τα φίλτρα median και οι προσαρμοστικές μέθοδοι εξομάλυνσης είναι διαδεδομένες στις ιατρικές εφαρμογές. Επιπλέον, οι προσαρμοστικές μέθοδοι, όπως τα φίλτρα anisotropic diffusion, προσφέρουν βελτιωμένη εξομάλυνση διατηρώντας τα περιγράμματα των δομών [17], [45], [47].

Ανίχνευση και Απομάκρυνση Αποκλίσεων: Μέθοδοι όπως το Local Outlier Factor (LOF) και το clustering με k-means χρησιμοποιούνται για την ταυτοποίηση δεδομένων που αποκλίνουν από τον κανόνα, μειώνοντας τις παραμορφώσεις στα δεδομένα εκπαίδευσης και ενισχύοντας την ποιότητα του μοντέλου [45], [47].

Τυποποίηση και Κανονικοποίηση Δεδομένων

Η εξασφάλιση συνέπειας μεταξύ διαφορετικών χαρακτηριστικών είναι κρίσιμη για την αποτελεσματική εκπαίδευση των μοντέλων. Τεχνικές όπως η κανονικοποίηση (min-max scaling), η τυποποίηση Z-score και η log-scaling εξασφαλίζουν τη σωστή κατανομή τιμών, βελτιώνοντας την εκπαίδευση του μοντέλου και μειώνοντας τις πιθανότητες υπερπροσαρμογής. Ειδικά στις 3D απεικονίσεις, η τυποποίηση ενισχύει την ισορροπία των εντάσεων μεταξύ διαφορετικών σαρώσεων, διασφαλίζοντας την ομοιογένεια των δεδομένων εισόδου [48].

Μείωση Διαστάσεων

Η μείωση διαστάσεων είναι εξαιρετικά χρήσιμη σε δεδομένα υψηλής ανάλυσης, όπως είναι οι 3D εικόνες MRI και CT. Τεχνικές όπως η Ανάλυση Κύριων Συνιστωσών (PCA) και οι autoencoders εξασφαλίζουν την αποδοτική επεξεργασία χωρίς να θυσιάζονται σημαντικές πληροφορίες. Οι autoencoders, ειδικά, επιτρέπουν την ανακάλυψη κρυφών

δομών στα δεδομένα, βελτιώνοντας την ποιότητα της τμηματοποίησης μέσω της συμπίεσης και της επανακατασκευής των δεδομένων [17], [50].

2.3.2 Επαύξηση Δεδομένων (Data Augmentation)

Η επαύξηση δεδομένων αποτελεί βασικό εργαλείο για τη βελτίωση της απόδοσης των μοντέλων, ιδιαίτερα σε περιπτώσεις περιορισμένων δεδομένων. Επιτρέπει την αύξηση της ποικιλομορφίας και της ανθεκτικότητας των δεδομένων. [42], [43].

Βασικές Τεχνικές Επαύξησης

Γεωμετρικοί Μετασχηματισμοί: Οι τεχνικές αυτές περιλαμβάνουν περιστροφή, κλίμακα, αντιστροφή και μετατόπιση. Εφαρμόζονται συχνά στις 3D εικόνες MRI και CT για να αντιμετωπίσουν την ποικιλομορφία στην εμφάνιση όγκων και άλλων παθολογιών [42]. Επιπλέον, οι τεχνικές όπως η ελαστική παραμόρφωση (elastic deformation) προσφέρουν πιο ρεαλιστικές παραλλαγές των δεδομένων, βελτιώνοντας την ανθεκτικότητα των μοντέλων σε διακυμάνσεις στη μορφολογία [51].

Αλλαγές στον Χρωματικό Χώρο: Τεχνικές όπως η αλλαγή αντίθεσης, φωτεινότητας και η κανονικοποίηση επιτρέπουν την προσαρμογή του μοντέλου σε διαφορετικές συνθήκες φωτισμού και σκάνερ, διατηρώντας την ακρίβεια της τμηματοποίησης. Αυτές οι αλλαγές βοηθούν τα μοντέλα να είναι πιο ανθεκτικά σε ποικίλες συνθήκες λήψης εικόνων [43].

Εισαγωγή Θορύβου: Η χρήση Gaussian noise και άλλων τύπων θορύβου ενισχύει την ανθεκτικότητα των μοντέλων σε θορυβώδη δεδομένα, προάγοντας την γενίκευση και την ακρίβεια σε πραγματικές συνθήκες [43], [44]. Επιπλέον, η εισαγωγή θορύβου βοηθά στην αποφυγή της υπερπροσαρμογής, καθιστώντας τα μοντέλα πιο σταθερά απέναντι σε διακυμάνσεις των δεδομένων.

Προηγμένες Τεχνικές Επαύξησης

Τα Generative Adversarial Networks (GANs) αποτελούν κορυφαία μέθοδο για τη δημιουργία ρεαλιστικών δειγμάτων εικόνων, ενισχύοντας την ποικιλομορφία των δεδομένων. Αυτή η τεχνική είναι ιδιαίτερα χρήσιμη σε εφαρμογές με περιορισμένα ή σπάνια δεδομένα, καθώς επιτρέπει τη δημιουργία συνθετικών εικόνων που διατηρούν τις κλινικές ιδιαιτερότητες. Παράλληλα, οι μεθοδολογίες αυτόματης επαύξησης, όπως το AutoAugment και το RandAugment, αυτοματοποιούν την επιλογή στρατηγικών επαύξησης μέσω meta-learning, μειώνοντας την ανάγκη χειροκίνητης βελτιστοποίησης και αυξάνοντας την αποτελεσματικότητα. Αυτές οι τεχνικές χρησιμοποιούν αλγόριθμους

βελτιστοποίησης για να εντοπίσουν τις βέλτιστες συνδυαστικές στρατηγικές επαύξησης, προσαρμόζοντας αυτόματα τις παραμέτρους για κάθε σύνολο δεδομένων. [27], [42], [45] [44], [45][25].

Ειδικές Εφαρμογές στην Ιατρική Εικόνα

Σε τρισδιάστατες ιατρικές εικόνες χρησιμοποιούνται εξειδικευμένες τεχνικές, όπως η παραμόρφωση voxel και η προσαρμογή χωρικών χαρακτηριστικών, για τη διατήρηση της κλινικής σημασίας των δεδομένων. Αυτές οι μέθοδοι εξασφαλίζουν ότι τα δεδομένα παραμένουν χρήσιμα για εφαρμογές όπως η τμηματοποίηση όγκων, διατηρώντας την ακρίβεια και την αξιοπιστία των αποτελεσμάτων. Επιπλέον, η χρήση τεχνικών όπως η patch-based επεξεργασία και η multi-scale επαύξηση συμβάλλει στην καλύτερη κατανόηση και ανάλυση των λεπτομερειών των 3D δομών [17], [39].

2.4 Τεχνικές Ερμηνευσιμότητας

Η ερμηνευσιμότητα σε συστήματα τεχνητής νοημοσύνης (AI) αναφέρεται στην ικανότητα κατανόησης και αξιολόγησης των αποφάσεων και της συλλογιστικής που διέπουν τις προβλέψεις από μοντέλα AI. Τα συστήματα τεχνητής νοημοσύνης είναι γνωστά για την αξιοσημείωτη απόδοσή τους στην ταξινόμηση εικόνων, την ανίχνευση αντικειμένων, την τμηματοποίηση εικόνων και πολλά άλλα. Ωστόσο, συχνά θεωρούνται «μαύρα κουτιά» επειδή μπορεί να είναι δύσκολο να κατανοήσουμε πώς η εσωτερική τους λειτουργία δημιουργεί συγκεκριμένες προβλέψεις. Οι τεχνικές ερμηνευσιμότητας στοχεύουν να αποκαλύψουν την εσωτερική λειτουργία των συστημάτων AI, προσφέροντας πληροφορίες για τις προβλέψεις τους [49], [53].

Το Εθνικό Ινστιτούτο Προτύπων και Τεχνολογίας (NIST) πρότεινε τέσσερις βασικές έννοιες για την ερμηνευσιμότητα AI (XAI) [59]:

- **Εξήγηση:** Το σύστημα παρέχει λόγους για τα αποτελέσματά του.
- **Σημαντικότητα:** Οι εξηγήσεις είναι κατανοητές στο κοινό-στόχο.
- **Ακρίβεια:** Οι εξηγήσεις αντικατοπτρίζουν σωστά τη συλλογιστική του συστήματος.
- **Όρια γνώσης:** Το σύστημα λειτουργεί εντός του σχεδιασμένου πεδίου εφαρμογής και των επιπέδων εμπιστοσύνης του.

Μία από τις θεμελιώδεις διακρίσεις στις προσεγγίσεις για την ερμηνευσιμότητα αφορά τον διαχωρισμό μεταξύ ενδογενών (intrinsic) και επεξηγηματικών (post-hoc) με-

θόδων. Οι ενδογενείς μέθοδοι ενσωματώνουν την ικανότητα ερμηνευσιμότητας κατά το σχεδιασμό και την κατασκευή του μοντέλου, έτσι ώστε οι εξηγήσεις να είναι εγγενείς στη λειτουργία του συστήματος. Αντίθετα, οι επεξηγηματικές μέθοδοι εφαρμόζονται μετά την εκπαίδευση του μοντέλου, αποσκοπώντας στο να αποκαλύψουν τους μηχανισμούς πίσω από τις προβλέψεις, χωρίς να αλλάζουν την αρχιτεκτονική του ίδιου του μοντέλου [54], [56].

Οι τεχνικές ερμηνευσιμότητας έχουν αναπτυχθεί με σκοπό να “ανοίξουν το μαύρο κουτί” των μοντέλων AI. Κύριες προσεγγίσεις περιλαμβάνουν:

- Οπτικοποιήσεις χαρτών ενεργοποίησης (π.χ., Grad-CAM)
- Τοπικές τεχνικές εξήγησης όπως το LIME και το SHAP
- Μεθόδους βασισμένες σε μετρήσεις κλίσης, όπως τα Integrated Gradients

Σε εφαρμογές όπως η ιατρική απεικόνιση, η χρήση αυτών των τεχνικών αποδεικνύεται ιδιαίτερα χρήσιμη. Για παράδειγμα, σε μοντέλα που χρησιμοποιούνται για την τμηματοποίηση όγκων και τη διάγνωση ασθενειών μέσω μεθόδων απεικόνισης (όπως MRI και CT), οι οπτικοποιήσεις βοηθούν τους κλινικούς ιατρούς να εντοπίσουν τις κρίσιμες περιοχές που επηρέασαν την απόφαση του μοντέλου [49], [58]. Επιπλέον, σε μοντέλα που βασίζονται σε αρχιτεκτονικές Transformers, η ανάλυση των attention weights προσφέρει μια επιπλέον οπτική στην κατανόηση της συμβολής των διαφόρων τμημάτων της εισόδου [52], [56].

Η επιλογή της καταλληλότερης μεθόδου εξαρτάται από την πολυπλοκότητα του μοντέλου και τις απαιτήσεις της εφαρμογής. Σε απλούστερα συστήματα, οι ενδογενείς μέθοδοι μπορεί να προσφέρουν άμεσες και ευθύγραμμη εξηγήσεις, ενώ σε πιο σύνθετα μοντέλα συνήθως συνδυάζονται επεξηγηματικές και υβριδικές προσεγγίσεις για μια πληρέστερη κατανόηση των εσωτερικών διεργασιών [57].

Παρά τις σημαντικές προόδους, παραμένουν προκλήσεις όπως η ανάγκη για μεγάλα και ποιοτικά σύνολα δεδομένων, η διαχείριση του θορύβου και των μεροληψιών, καθώς και τα προβλήματα που σχετίζονται με την υπερπροσαρμογή και την καταστροφική λήθη σε βαθιά νευρωνικά δίκτυα. Η αντιμετώπιση αυτών των ζητημάτων αποτελεί αντικείμενο εντατικής έρευνας με νέες μεθοδολογίες να αναπτύσσονται συνεχώς για την καλύτερη κατανόηση και ερμηνεία των μοντέλων AI [48].

Συνολικά, η ερμηνευσιμότητα παραμένει θεμέλιος λίθος για την ανάπτυξη διαφανών συστημάτων AI. Η συνεχής βελτίωση των μεθόδων εξήγησης, με σαφή διαχωρισμό μεταξύ ενδογενών και επεξηγηματικών προσεγγίσεων, θα διευκολύνει την ευρύτερη εφαρ-

μογή της τεχνολογίας και θα ενισχύσει την εμπιστοσύνη των χρηστών, συμβάλλοντας στην ηθική και ασφαλή ανάπτυξη της τεχνητής νοημοσύνης [39], [55].

2.5 Μελλοντικές Τάσεις στην Τρισδιάστατη Τμηματοποίηση

Η τρισδιάστατη τμηματοποίηση παραμένει ένα από τα ταχύτερα εξελισσόμενα πεδία στην τεχνητή νοημοσύνη για ιατρικές εφαρμογές. Παρά τις έως τώρα επιτυχίες, η κλινική αξιοποίηση περιορίζεται από ζητήματα όπως η υπολογιστική πολυπλοκότητα, η ανάγκη για μεγάλα και ποιοτικά δεδομένα, καθώς και η ελλιπής ερμηνευσιμότητα των μοντέλων. Οι μελλοντικές προσπάθειες επικεντρώνονται στην ανάπτυξη νέων αρχιτεκτονικών, βελτιωμένων τεχνικών εκπαίδευσης και καινοτόμων μεθοδολογιών που στοχεύουν σε υψηλότερα επίπεδα γενίκευσης, διαφάνειας και αποδοτικότητας [1], [2].

Οι μετασχηματιστές (transformers) έχουν φέρει επανάσταση στην τρισδιάστατη τμηματοποίηση, ειδικά μέσω μοντέλων όπως το Swin Transformer και το CoTr, τα οποία εκμεταλλεύονται την ικανότητά τους να αναλύουν μακροχρόνιες εξαρτήσεις και να επεξεργάζονται δεδομένα σε πολλαπλές κλίμακες [23], [27]. Ωστόσο, οι υψηλές απαιτήσεις σε δεδομένα και η μεγάλη υπολογιστική πολυπλοκότητα αποτελούν σημαντικά εμπόδια για την κλινική εφαρμογή. Η μελλοντική έρευνα θα πρέπει να επικεντρωθεί στη βελτιστοποίηση της αποδοτικότητας των μετασχηματιστών μέσω τεχνικών όπως η μεταφορά μάθησης (transfer learning) και η χρήση πιο αποδοτικών αρχιτεκτονικών [14], [44]. Επιπλέον, η ενσωμάτωση των μετασχηματιστών σε υβριδικές αρχιτεκτονικές που συνδυάζουν CNNs και transformers μπορεί να προσφέρει τα πλεονεκτήματα και των δύο προσεγγίσεων, βελτιώνοντας την ικανότητα των μοντέλων να συλλαμβάνουν πολύπλοκες χωρικές σχέσεις και να προσαρμόζονται σε ετερογενή δεδομένα [42].

Οι υβριδικές αρχιτεκτονικές, όπως το nnFormer και το HarDNet Transformer, προσφέρουν λύσεις συνδυάζοντας τοπικές και παγκόσμιες αναλύσεις, επιτυγχάνοντας καλύτερη γενίκευση και ευκολότερη προσαρμογή σε διαφορετικά δεδομένα [32], [36]. Αυτές οι αρχιτεκτονικές αξιοποιούν τα πλεονεκτήματα των CNNs στην ανίχνευση τοπικών χαρακτηριστικών και των transformers στην κατανόηση μακροπρόθεσμων εξαρτήσεων, επιτρέποντας την αποτελεσματικότερη ανάλυση πολύπλοκων 3D δομών. Ενώ τα υβριδικά μοντέλα έχουν δείξει υψηλή απόδοση σε διάφορες εφαρμογές, οι μελλοντικές εργασίες θα πρέπει να διερευνήσουν την κλιμάκωση αυτών των αρχιτεκτονικών για

μεγάλες βάσεις δεδομένων και τη βελτίωση της συμβατότητας με διαφορετικούς τύπους ιατρικών απεικονίσεων [21], [23].

Η αυτοεποπτευόμενη μάθηση (self-supervised learning, SSL) αναδεικνύεται ως λύση στην περιορισμένη διαθεσιμότητα επισημασμένων δεδομένων, που αποτελεί ένα από τα μεγαλύτερα εμπόδια στην ανάπτυξη μοντέλων για 3D τμηματοποίηση. Τεχνικές όπως το SimCLR και τα Masked Autoencoders επιτρέπουν την αξιοποίηση μη επισημασμένων δεδομένων μέσω προκαθορισμένων tasks, όπως η πρόβλεψη τμήματος της εικόνας ή η ανακατασκευή της εισόδου από μια παραμορφωμένη έκδοση της [20], [30]. Παρόλα αυτά, τα τρέχοντα μοντέλα SSL συχνά απαιτούν εκτεταμένη υπολογιστική ισχύ και είναι δύσκολο να εφαρμοστούν σε πολυτροπικά δεδομένα λόγω της διαφορετικότητας των χαρακτηριστικών από κάθε απεικόνιση. Η μελλοντική έρευνα πρέπει να επικεντρωθεί στη μείωση της υπολογιστικής πολυπλοκότητας μέσω βελτιωμένων αρχιτεκτονικών και στην ενσωμάτωση δεδομένων διαφορετικών τύπων και μορφών, επιτρέποντας τη δημιουργία πιο ευέλικτων και αποδοτικών μοντέλων [44], [50].

Τα Generative Adversarial Networks (GANs) συνεχίζουν να διαδραματίζουν καθοριστικό ρόλο στην αντιμετώπιση της έλλειψης δεδομένων. Η παραγωγή συνθετικών δεδομένων υψηλής ποιότητας από μοντέλα όπως το MedGAN και το 3D-StyleGAN ενισχύει την απόδοση των μοντέλων τμηματοποίησης και τη γενίκευση [17], [19]. Οι GANs χρησιμοποιούνται για τη δημιουργία ρεαλιστικών 3D εικόνων που μπορούν να επεκτείνουν το υπάρχον σύνολο δεδομένων χωρίς την ανάγκη πρόσθετης χειροκίνητης συλλογής, διατηρώντας παράλληλα τις κλινικές ιδιαιτερότητες των δεδομένων [18]. Ωστόσο, η χρήση GANs παραμένει περιορισμένη λόγω της δυσκολίας στη σταθερή εκπαίδευση και της ανάγκης για εποπτευόμενη αξιολόγηση της ποιότητας των παραγόμενων δεδομένων. Η μελλοντική έρευνα θα μπορούσε να επικεντρωθεί σε καλύτερες μεθόδους αξιολόγησης και στη χρήση GANs για δυναμική προσαρμογή δεδομένων σε πραγματικό χρόνο, ενισχύοντας την αξιοπιστία και την πρακτική εφαρμογή τους σε κλινικά περιβάλλοντα [13], [16].

Η ανάγκη για ασφάλεια και προστασία προσωπικών δεδομένων έχει αναδείξει την ομοσπονδιακή μάθηση (federated learning) ως κρίσιμη τάση στην ιατρική τμηματοποίηση. Αυτή η τεχνολογία επιτρέπει τη συνεργατική εκπαίδευση μοντέλων χωρίς την ανάγκη κοινής χρήσης δεδομένων μεταξύ οργανισμών, διατηρώντας την ιδιωτικότητα των ασθενών [11], [22]. Οι ομοσπονδιακές αρχιτεκτονικές επιτρέπουν στους οργανισμούς να εκπαιδεύουν μοντέλα τοπικά και να μοιράζονται μόνο τα βαρύτητά τους (model

weights) με έναν κεντρικό διακομιστή, μειώνοντας τους κινδύνους παραβίασης δεδομένων. Αν και έχει σημειωθεί πρόοδος, παραμένουν ζητήματα όπως η ανομοιογένεια των δεδομένων (data heterogeneity) και η αύξηση του υπολογιστικού κόστους λόγω της αποκεντρωμένης φύσης της μάθησης. Μελλοντική έρευνα θα πρέπει να επικεντρωθεί στην αποτελεσματική αντιμετώπιση αυτών των ζητημάτων μέσω βελτιωμένων αλγορίθμων συγχώνευσης μοντέλων και στην ανάπτυξη πιο αποδοτικών μηχανισμών επικοινωνίας [28], [35].

Η ερμηνευσιμότητα των μοντέλων βαθιάς μάθησης παραμένει ένα σημαντικό εμπόδιο για την ευρεία αποδοχή τους στην ιατρική. Μέθοδοι όπως το Grad-CAM και το Guided Grad-CAM παρέχουν οπτικοποιήσεις που διευκολύνουν την κατανόηση του τρόπου λειτουργίας των μοντέλων [25], [26]. Αυτές οι τεχνικές βοηθούν στην ενίσχυση της διαφάνειας και στην αύξηση της εμπιστοσύνης των ιατρικών επαγγελματιών στα συστήματα AI. Ωστόσο, παραμένουν προκλήσεις όπως η χαμηλή ανάλυση των εξηγήσεων και η αβεβαιότητα στις προβλέψεις, που μπορούν να επηρεάσουν την αξιοπιστία των εξηγήσεων. Η ενσωμάτωση XAI (Explainable AI) τεχνικών σε σύγχρονες αρχιτεκτονικές, όπως οι μετασχηματιστές, αποτελεί βασική κατεύθυνση για την γεφύρωση του χάσματος μεταξύ τεχνητής νοημοσύνης και κλινικής πρακτικής [30]. Επιπλέον, η συνδυαστική χρήση διάφορων τεχνικών ερμηνευσιμότητας μπορεί να προσφέρει πιο ολοκληρωμένες και αξιόπιστες εξηγήσεις, ενισχύοντας την εμπιστοσύνη των ιατρικών επαγγελματιών και βελτιώνοντας τη συνολική ποιότητα των ιατρικών αποφάσεων [24].

Ο συνδυασμός πολυτροπικών δεδομένων (π.χ. MRI, CT, PET) σε ένα ενιαίο pipeline τμηματοποίησης παρέχει περισσότερες δυνατότητες για ακριβέστερη ανάλυση. Τα Multi-Modal Transformers (MMFormer) είναι παραδείγματα που επιδεικνύουν τη δύναμη της συνδυαστικής ανάλυσης, αξιοποιώντας τα πλεονεκτήματα διαφορετικών απεικονιστικών τεχνικών για την εξαγωγή πλουσιότερων χαρακτηριστικών [33]. Αυτές οι προσεγγίσεις επιτρέπουν την ενσωμάτωση πολλαπλών πηγών πληροφορίας, βελτιώνοντας την ακρίβεια και την ανθεκτικότητα των μοντέλων στην ανίχνευση και τμηματοποίηση παθολογιών. Μελλοντική έρευνα θα μπορούσε να εστιάσει στην ενσωμάτωση πολυτροπικών δεδομένων από διαφορετικές πηγές με στόχο τη βελτίωση της ακρίβειας και της γενίκευσης. Επιπλέον, η ανάπτυξη πιο αποδοτικών μηχανισμών συγχώνευσης και επεξεργασίας πολυτροπικών χαρακτηριστικών μπορεί να ενισχύσει περαιτέρω την απόδοση των μοντέλων τμηματοποίησης σε πραγματικές κλινικές συνθήκες [34], [37].

2.6 Σύνοψη της Βιβλιογραφικής Ανασκόπησης

Στη συγκεκριμένη βιβλιογραφική ανασκόπηση, διερευνήθηκε ο πολυδιάστατος ρόλος της τεχνητής νοημοσύνης στην τρισδιάστατη τμηματοποίηση εγκεφαλικών όγκων και η σημασία της στην κλινική πρακτική. Αρχικά, παρουσιάστηκαν οι κλινικές παράμετροι που καθιστούν την ακριβή τμηματοποίηση κρίσιμη για τη διάγνωση, την εξατομικευμένη θεραπεία και την παρακολούθηση της εξέλιξης των όγκων. Στη συνέχεια, αναδείχθηκαν οι τεχνικές καινοτομίες που υποστηρίζουν την αυτοματοποιημένη τρισδιάστατη τμηματοποίηση, συμπεριλαμβανομένης της εξέλιξης από τις κλασικές μεθόδους σε εξελιγμένες αρχιτεκτονικές βαθιάς μάθησης και υβριδικές λύσεις που συνδυάζουν CNNs με Transformers.

Ιδιαίτερη έμφαση δόθηκε στη σημασία της προεπεξεργασίας και της επαύξησης δεδομένων για την αντιμετώπιση της περιορισμένης διαθεσιμότητας ποιοτικών ιατρικών απεικονίσεων, καθώς και στη χρήση τεχνικών ερμηνευσιμότητας (π.χ. Grad-CAM) για την ενίσχυση της εμπιστοσύνης των κλινικών επαγγελματιών. Επιπλέον, συζητήθηκαν οι ηθικές, νομικές, και οργανωτικές προκλήσεις που δυσχεραίνουν την εφαρμογή αυτών των συστημάτων στην καθημερινή κλινική πρακτική.

Τέλος, η ανασκόπηση παρουσίασε μελλοντικές τάσεις, όπως η βελτίωση των υβριδικών αρχιτεκτονικών, η αυτοεποπτευόμενη μάθηση και η ομοσπονδιακή μάθηση, που υπόσχονται να αυξήσουν τη γενίκευση, την ανθεκτικότητα και την αποδοχή των μοντέλων τεχνητής νοημοσύνης. Συνολικά, η επισκόπηση αυτή ανέδειξε τη δυναμική εξέλιξη του πεδίου, τις υπάρχουσες προκλήσεις και τις μελλοντικές κατευθύνσεις που θα καθορίσουν την κλινική αξιοποίηση των τεχνολογιών τρισδιάστατης τμηματοποίησης εγκεφαλικών όγκων.

3 Μεθοδολογία

Η παρούσα εργασία επικεντρώνεται στη συγκριτική αξιολόγηση σύγχρονων αρχιτεκτονικών βαθιάς μάθησης για την τρισδιάστατη τμηματοποίηση όγκων εγκεφάλου, χρησιμοποιώντας το ευρέως αναγνωρισμένο σύνολο δεδομένων BraTS. Η μεθοδολογική προσέγγιση που ακολουθήθηκε διαρθρώνεται σε τέσσερις βασικούς άξονες: την προετοιμασία των δεδομένων, την επιλογή και υλοποίηση των μοντέλων, την εκπαίδευση και αξιολόγηση των μοντέλων.

Στο πρώτο στάδιο της μεθοδολογίας, εστιάζουμε στην ανάλυση και προετοιμασία του συνόλου δεδομένων BraTS. Το συγκεκριμένο σύνολο δεδομένων επιλέχθηκε λόγω της πληρότητας και της ποιότητας των label του, καθώς και της ευρείας αποδοχής του από την ερευνητική κοινότητα ως σημείο αναφοράς για την αξιολόγηση αλγορίθμων τμηματοποίησης. Η τυχόν προ-επεξεργασία των δεδομένων γίνεται μόνο μέσα από τα ίδια τα μοντέλα και εμείς δεν έχουμε πρόσθεση επιπλέον βήματα προεπεξεργασίας. Με αυτόν τον τρόπο είμαστε σίγουροι ότι συγκρίνουμε τις αρχικές αρχιτεκτονικές χωρίς παρεμβολές από τυχόν αλλαγές στα δεδομένα.

Για τη συγκριτική μελέτη, επιλέχθηκαν τρεις διαφορετικές αρχιτεκτονικές που αντιπροσωπεύουν τις τελευταίες εξελίξεις στον τομέα. Συγκεκριμένα επιλέχθηκε ένα μοντέλο βασισμένο σε Convolutional Neural Networks (Deepmedic), ένα που αξιοποιεί transformers (ViT), ένα βασισμένο στην αρχιτεκτονική U-Net (U-Net) και ένα υβριδικό μοντέλο που συνδυάζει και τις δύο προσεγγίσεις (TransBTS). Η επιλογή αυτών των μοντέλων έγινε με γνώμονα την αντιπροσώπευση διαφορετικών προσεγγίσεων στην τρισδιάστατη τμηματοποίηση και τη δυνατότητα σύγκρισης των πλεονεκτημάτων και περιορισμών κάθε αρχιτεκτονικής.

Η εκπαίδευση των μοντέλων πραγματοποιήθηκε με χρήση σύγχρονων τεχνικών βελτιστοποίησης και τεχνικών κανονικοποίησης, ενώ η αξιολόγηση βασίστηκε σε καθιερωμένες μετρικές όπως ο δείκτης Dice, η ευαισθησία και η ακρίβεια. Για την εξασφάλιση της αξιοπιστίας των αποτελεσμάτων, εφαρμόστηκε διασταυρούμενη επικύρωση και χρησιμοποιήθηκε ξεχωριστό σύνολο δεδομένων ελέγχου.

Στις επόμενες ενότητες παρουσιάζονται αναλυτικά τα επιμέρους στοιχεία της προσέγγισης, ξεκινώντας από την περιγραφή του συνόλου δεδομένων BraTS, και τα βήματα προετοιμασίας που εφαρμόστηκαν.

3.1 Δεδομένα

Η επιτυχής ανάπτυξη και αξιολόγηση μοντέλων τρισδιάστατης τμηματοποίησης εγκεφαλικών όγκων, προϋποθέτει την αξιοποίηση ενός αξιόπιστου και καλά επισημειωμένου συνόλου δεδομένων. Το σύνολο δεδομένων BraTS έχει καθιερωθεί ως το πρότυπο αναφοράς στην ερευνητική κοινότητα, παρέχοντας υψηλής ποιότητας απεικονίσεις μαγνητικού συντονισμού (MRI) από πολλαπλά κλινικά κέντρα, μαζί με λεπτομερείς labels από έμπειρους ακτινολόγους [1], [10], [16].

3.1.1 Περιγραφή του Συνόλου Δεδομένων BraTS

Το σύνολο δεδομένων BraTS 2021, το οποίο χρησιμοποιήθηκε στην παρούσα μελέτη, περιλαμβάνει πολυτροπικές απεικονίσεις μαγνητικού συντονισμού από 2,000 ασθενείς με επιβεβαιωμένη διάγνωση γλοιώματος [20]. Κάθε περίπτωση στο σύνολο δεδομένων συνοδεύεται από τέσσερις διαφορετικές ακολουθίες MRI, οι οποίες παρέχουν συμπληρωματικές πληροφορίες για την ακριβή διάγνωση και τμηματοποίηση των όγκων [1]. Συγκεκριμένα, η ακολουθία T1-weighted (T1) παρέχει λεπτομερείς ανατομικές πληροφορίες και την βασική δομή του εγκεφάλου, ενώ η ακολουθία T1-weighted με σκιαγραφικό (T1ce) αναδεικνύει περιοχές με διαταραχή του αιματοεγκεφαλικού φραγμού. Η ακολουθία T2-weighted (T2) είναι ιδιαίτερα χρήσιμη για την απεικόνιση του οιδήματος και της συνολικής έκτασης του όγκου, ενώ η ακολουθία T2-FLAIR προσφέρει βελτιωμένη αντίθεση για την αναγνώριση περιφερικών βλαβών, μέσω της καταστολής του σήματος του εγκεφαλονωτιαίου υγρού [10].

Οι απεικονίσεις έχουν τυποποιηθεί σε ανάλυση $240 \times 240 \times 155$ voxels, με ισοτροπικό μέγεθος voxel 1mm^3 [20], εξασφαλίζοντας συνέπεια στην ανάλυση των δεδομένων. Οι επισημειώσεις (labels) των απεικονίσεων, οι οποίες έχουν πραγματοποιηθεί από έμπειρους ακτινολόγους, διακρίνουν τρεις κρίσιμες περιοχές του όγκου: τον ενισχυόμενο πυρήνα (ET - Enhancing Tumor), την περιοχή οιδήματος, και τον νεκρωτικό και μη ενισχυόμενο πυρήνα του όγκου. Αυτός ο διαχωρισμός αντανακλά τη διαφορετική βιολογική συμπεριφορά και κλινική σημασία κάθε περιοχής [1], [10].

3.2 Μοντέλα

Η τμηματοποίηση εγκεφαλικών όγκων από τρισδιάστατες εικόνες μαγνητικής τομογραφίας (MRI), αποτελεί κρίσιμη διαδικασία στη διάγνωση και παρακολούθηση της εξέλιξης των παθολογιών του εγκεφάλου. Οι εξελίξεις στη μηχανική μάθηση και τη βαθιά μάθηση (deep learning) έχουν επιτρέψει την ανάπτυξη προηγμένων αλγορίθμων που επιτυγχάνουν υψηλή ακρίβεια σε αυτό το πρόβλημα, βασιζόμενοι είτε σε συνελκτικά νευρωνικά δίκτυα (CNNs) είτε σε Transformers.

Το παρόν κεφάλαιο επικεντρώνεται στην παρουσίαση και ανάλυση τεσσάρων διαφορετικών αρχιτεκτονικών, που έχουν προταθεί για την τρισδιάστατη τμηματοποίηση εγκεφαλικών όγκων, καλύπτοντας ένα ευρύ φάσμα προσεγγίσεων. Η πρώτη κατηγορία αφορά καθαρά CNN μοντέλα, όπως το DeepMedic [17], το οποίο βασίζεται στη χρήση πολλαπλών pathways για την εκμετάλλευση τόσο τοπικών όσο και ευρύτερων χωρικών πληροφοριών. Η δεύτερη προσέγγιση είναι η υβριδική μέθοδος, όπου το TransBTS [60] συνδυάζει CNNs με Transformers, αξιοποιώντας την τοπική ανάλυση των συνελκτικών φίλτρων και τα μακροχρόνια εξαρτημένα μοτίβα που εντοπίζουν οι Transformers. Το U-Net [61] αντιπροσωπεύει την κλασική κατηγορία των encoder-decoder CNNs, αξιοποιώντας ένα συμμετρικό αρχιτεκτονικό σχεδιασμό με skip connections, ενώ το Vision Transformer (ViT) [62] διερευνά τη δυνατότητα χρήσης καθαρών Transformer μοντέλων, μετατρέποντας τις εικόνες σε ακολουθίες από patches χωρίς τη χρήση συνελκτικών φίλτρων.

Η επιλογή αυτών των τεσσάρων μοντέλων έγινε με σκοπό να συμπεριληφθούν διαφορετικές τεχνολογικές προσεγγίσεις, επιτρέποντας τη σύγκριση μεταξύ παραδοσιακών CNNs, υβριδικών λύσεων και Transformer-based μεθόδων. Η ανάλυση των μοντέλων θα επικεντρωθεί στα βασικά χαρακτηριστικά τους, στα πλεονεκτήματα και τις αδυναμίες τους, καθώς και στην απόδοσή τους σε πραγματικά δεδομένα από το BraTS dataset.

3.2.1 Επιλογή Μοντέλων προς Σύγκριση

Η επιλογή των παραπάνω τεσσάρων μοντέλων δεν ήταν τυχαία, αλλά βασίστηκε σε συγκεκριμένα κριτήρια που αφορούν τόσο την τεχνική ποικιλομορφία όσο και την ιστορική τους επίδοση στη βιβλιογραφία της τμηματοποίησης εγκεφαλικών όγκων.

Το DeepMedic επιλέχθηκε καθώς αποτελεί ένα από τα πιο καθιερωμένα 3D CNN μοντέλα, που έχει επανειλημμένα αποδειχθεί αποδοτικό στη βιβλιογραφία και έχει καταγράψει υψηλές επιδόσεις σε διαγωνισμούς, όπως το BraTS Challenge. Η βασική του

καινοτομία έγκειται στην dual pathway αρχιτεκτονική του, η οποία επιτρέπει την ταυτόχρονη επεξεργασία της εικόνας σε δύο διαφορετικές κλίμακες ανάλυσης. Με αυτόν τον τρόπο, το DeepMedic μπορεί να εξάγει λεπτομερείς πληροφορίες από τα τοπικά patches, ενώ παράλληλα διατηρεί τη συνολική χωρική κατανόηση των δεδομένων. Αυτή η στρατηγική προσφέρει αντίσταση στον θόρυβο και βελτιώνει τη γενίκευση του μοντέλου.

Το TransBTS επιλέχθηκε διότι αντιπροσωπεύει τη σύγχρονη υβριδική προσέγγιση, συνδυάζοντας την τοπική ανάλυση των CNNs με την παγκόσμια χωρική συσχέτιση που προσφέρουν οι Transformers. Το CNN λειτουργεί ως ένας ισχυρός feature extractor, ενώ το Transformer επιτρέπει την ενσωμάτωση μακροπρόθεσμων εξαρτήσεων μέσα στο 3D MRI scan. Το μοντέλο αυτό επιλέχθηκε προκειμένου να διερευνηθεί εάν η υβριδική προσέγγιση υπερτερεί έναντι των καθαρών CNN ή Transformer μοντέλων, ειδικά σε μικρότερες ποσότητες δεδομένων, όπου οι Transformers τείνουν να δυσκολεύονται.

Το U-Net είναι ένα από τα πιο αναγνωρισμένα μοντέλα στον χώρο της ιατρικής τμηματοποίησης και για αυτόν τον λόγο συμπεριλήφθηκε στη σύγκριση. Η encoder-decoder αρχιτεκτονική του με skip connections, εξασφαλίζει υψηλή ευκρίνεια στις προβλέψεις, καθιστώντας το ιδιαίτερα αποτελεσματικό σε περιπτώσεις όπου απαιτείται ακριβής οριοθέτηση όγκων. Το U-Net έχει χρησιμοποιηθεί σε πολυάριθμες μελέτες και αποτελεί το βασικό σημείο αναφοράς για κάθε νέα προσέγγιση στην ιατρική τμηματοποίηση.

Τέλος, το ViT επιλέχθηκε ως το αντιπροσωπευτικό Transformer-only μοντέλο, προκειμένου να εξεταστεί κατά πόσο μπορεί να ανταγωνιστεί ή και να ξεπεράσει τις CNN-based προσεγγίσεις. Σε αντίθεση με τα CNNs, το ViT διαχειρίζεται τις εικόνες ως ακολουθίες από patches, δίνοντας τη δυνατότητα στον μηχανισμό αυτο-προσοχής (self-attention) να μάθει μακροχρόνιες εξαρτήσεις μέσα στην εικόνα. Η απόδοσή του στις τρισδιάστατες ιατρικές εικόνες, όπου τα δεδομένα είναι περιορισμένα, είναι ένα ανοιχτό ερώτημα και η σύγκριση με τα άλλα μοντέλα έχει ιδιαίτερη σημασία.

3.2.2 Περιγραφή των Αρχιτεκτονικών

Σε αυτήν την ενότητα, περιγράφονται οι αρχιτεκτονικές των τεσσάρων μοντέλων, εξηγώντας τη ροή των δεδομένων μέσα στα δίκτυα, τη δομή των layers και τις ιδιαιτερότητες κάθε προσέγγισης.

DeepMedic

Το **DeepMedic** είναι ένα multi-scale 3D CNN που χρησιμοποιεί **dual pathway processing** για την αποτύπωση τόσο λεπτομερών όσο και πιο ευρύτερων χαρακτηριστικών εικόνας [17]. Περιλαμβάνει:

- Ένα κύριο **CNN pathway**, το οποίο επεξεργάζεται patches υψηλής ανάλυσης.
- Ένα δεύτερο **pathway**, το οποίο επεξεργάζεται την ίδια εικόνα σε χαμηλότερη ανάλυση, για την ενσωμάτωση πιο γενικευμένων χαρακτηριστικών.
- **Post-processing με CRF (Conditional Random Fields)** για τη μείωση ψευδώς θετικών προβλέψεων.

TransBTS

Το **TransBTS** εισάγει ένα **Transformer-based μοντέλο τμηματοποίησης**, συνδυάζοντας CNN και self-attention layers για τη λήψη τοπικών και παγκόσμιων πληροφοριών [60]. Η δομή του περιλαμβάνει:

- Έναν **3D CNN encoder**, ο οποίος εξάγει χαρακτηριστικά από την είσοδο.
- Ένα **Transformer module**, που λαμβάνει ως είσοδο τα embeddings των χαρακτηριστικών και μαθαίνει μακροπρόθεσμες εξαρτήσεις.
- Έναν **CNN-based decoder**, που επαναφέρει την πλήρη ανάλυση των προβλέψεων.

U-Net

Το **U-Net** είναι ένα **encoder-decoder CNN**, το οποίο χρησιμοποιεί skip connections για τη διατήρηση λεπτομερών χαρακτηριστικών [61]. Η αρχιτεκτονική του περιλαμβάνει:

- Ένα **contracting path (encoder)**, που μειώνει τη διάσταση της εισόδου μέσω διαδοχικών convolutions και pooling layers.
- Ένα **expanding path (decoder)**, που χρησιμοποιεί upsampling layers και concatenation με τα features από το encoder.
- Ένα τελικό **convolutional layer**, που προβλέπει την τμηματοποίηση.

Vision Transformer (ViT)

Το **ViT** είναι ένα μοντέλο βασισμένο αποκλειστικά σε **Transformers**, το οποίο λειτουργεί με απευθείας **εφαρμογή attention σε τμήματα εικόνας (patches)** [62]. Περιλαμβάνει:

- Ένα **patch embedding layer**, που μετατρέπει τα τμήματα της εικόνας σε διανύσματα.
- Πολλαπλά **Transformer layers**, που εκτελούν self-attention για την εκμάθηση χαρακτηριστικών.
- Ένα **MLP head**, που χρησιμοποιείται για την πρόβλεψη των τμηματοποιημένων περιοχών.

3.2.3 Προετοιμασία Δεδομένων

DeepMedic




Figure 4

Για τις ανάγκες του DeepMedic, συνήθως δημιουργείται ένας κύριος φάκελος (π.χ. `deepmedic_data/`), όπου τοποθετούνται οι υποφάκελοι `train/`, `validation/` και (προαιρετικά) `test/`. Σε καθέναν από αυτούς προστίθενται φάκελοι για κάθε ασθενή, με τις αντίστοιχες ακολουθίες MRI (T1, T1c, T2, FLAIR) και τα αρχεία ετικετών (label maps). Για παράδειγμα:

```
0 | deepmedic_data/
```


Παράλληλα, δημιουργείται ένα ακόμα αρχείο κειμένου για τις ετικέτες (ground truth), π.χ. gtLabelsTrain.txt, το οποίο πρέπει να έχει ακριβώς τον ίδιο αριθμό γραμμών και την ίδια σειρά περιστατικών με τα αντίστοιχα αρχεία των modalities. Κατ' αντίστοιχο τρόπο, φτιάχνονται channel lists για το validation set (π.χ. channelsValidation_T1.txt, channelsValidation_T1c.txt, gtLabelsValidation.txt) έτσι ώστε το μοντέλο να γνωρίζει σε ποια διαδρομή βρίσκεται κάθε μορφή δεδομένων.

Ρύθμιση Αρχείων Παραμετροποίησης (.cfg files)

Για την εκπαίδευση στο DeepMedic χρησιμοποιούνται συνήθως τουλάχιστον δύο αρχεία ρυθμίσεων:

- **modelConfig.cfg**: Περιγράφει την αρχιτεκτονική του δικτύου (π.χ. μέγεθος patch, βάθος συνελκτικών στρωμάτων), τους αριθμούς καναλιών εισόδου, και διάφορες ρυθμίσεις που αφορούν τη δομή του CNN.
- **trainConfig.cfg**: Ορίζει τις διαδρομές (channel lists και labels), τα μεγέθη batch, τον αριθμό εποχών εκπαίδευσης και άλλες παραμέτρους που σχετίζονται με την εκπαίδευση.
- **testConfig.cfg**: Χρησιμοποιείτε για την εκτέλεση μιας αξιολόγησης ή/και inference σε καινούρια δεδομένα χωρίς ground truth

modelConfig.cfg

Περιγράφει τις παραμέτρους της αρχιτεκτονικής του δικτύου και αποτελεί τον «σχεδιασμό» για το πώς θα λειτουργήσει το CNN. Συνήθως, συμπεριλαμβάνει:

- **numberOfInputChannels**
Ο αριθμός των modalities (π.χ. 4 για T1, T1c, T2, FLAIR).
- **numberOfOutputClasses**
Πόσες είναι οι κατηγορίες εξόδου (π.χ. 4, συμπεριλαμβανομένου του background).
- **numberFMsPerLayerNormal** / **kernelDimPerLayerNormal**
Ο αριθμός των feature maps και οι διαστάσεις των πυρήνων συνελίξεων (π.χ. 3×3×3) στο normal-resolution pathway.
- **numberFMsPerLayerSubsampled** / **kernelDimPerLayerSubsampled**
Αν χρησιμοποιείται dual pathway (subsampled), ορίζονται ανάλογα οι παράμετροι των συνελκτικών επιπέδων.

- **numberFMsPerLayerFC** / **kernelDimPerLayerFC**
Οι fully-connected στρώσεις πριν την τελική ταξινόμηση, συνήθως με πυρήνα $1 \times 1 \times 1$.
- **segmentsDimTrain**
Οι διαστάσεις των 3D patches (segments) που θα κόβονται για την εκπαίδευση (π.χ. $15 \times 15 \times 15$).
- **activationFunction** / **dropoutRates***
Ο τύπος της ενεργοποίησης (π.χ. relu) και τα ποσοστά dropout ανά επίπεδο.
- **applyBatchNormalization**
Ενεργοποίηση ή όχι της ομαλοποίησης Batch Norm.
- **Regularization** & **Initialization**
Μέθοδοι τακτοποίησης (L2, L1) και αρχικοποίησης βαρών (π.χ. *he_normal*).
- **useResidualConnections** / **softmaxTemperature**
Επιλογή residual συνδέσεων και ρύθμιση «θερμοκρασίας» στο softmax.

Με αυτήν τη ρύθμιση, το DeepMedic γνωρίζει ακριβώς πόσα κανάλια/επίπεδα να περιμένει, πώς να εκτελέσει τις συνελίξεις και ποιον τύπο ταξινόμησης να εφαρμόσει.

trainConfig.cfg

Αφορά τις ρυθμίσεις που σχετίζονται με τα δεδομένα εκπαίδευσης, τον αριθμό εποχών, το μέγεθος batch και λοιπές λεπτομέρειες της διαδικασίας μάθησης. Κάποιες συνήθεις παράμετροι και τυπικές ρυθμίσεις είναι:

- **channels** και **channelsTraining**
Λίστα με τα modalities (π.χ. ["T1", "T1c", "T2", "FLAIR"]) και τα αρχεία κειμένου (.txt) που περιλαμβάνουν τις διαδρομές κάθε modality για το training (π.χ. *channelsTrain_T1.txt* κ.λπ.).
- **gtLabelsTraining**
Αρχείο .txt με τις διαδρομές των ετικετών (labels), ευθυγραμμισμένο σε σειρά με τα αντίστοιχα channel lists.
- **batchsize_train** & **patchDim**
Αριθμός 3D patches που θα περνά στο δίκτυο ανά βήμα, καθώς και οι διαστάσεις των patches (π.χ. $25 \times 25 \times 25$). Η επιλογή μεγάλων patches αυξάνει τις απαιτήσεις σε GPU μνήμη.
- **device**
Προσδιορίζει τη GPU που θα χρησιμοποιηθεί (π.χ. *cuda0*).

- **typeOfSamplingForTraining** & **proportionOfSamplesToExtractPerCategoryTraining**
Ορίζουν πώς γίνεται η δειγματοληψία των patches (π.χ. ξεχωριστή ανά κλάση, foreground/background).
- **numberOfEpochs**, **numberOfSubepochs** και **numOfCasesLoadedPerSubepoch** Ρυθμίζουν τον αριθμό εποχών εκπαίδευσης και πώς η διαδικασία «τεμαχίζεται» σε υπο-εποχές (subepochs).
- **Learning Rate**, **Momentum**, **Optimizer**
Προσδιορισμός ρυθμού μάθησης (π.χ. 0.001), optimizer (SGD, Adam, RMSProp) και τυχόν χρήσης momentum ή Nesterov.
- **Data Augmentation** (**augm_img_prms_tr**, **augm_sample_prms_tr**)
Παράμετροι που ελέγχουν γεωμετρικές μετασχηματίσεις (rotations, scaling) ή αλλοιώσεις έντασης (shift, scale).
- **Validation** **Settings**
Επιλογές για αυτόματο validation (π.χ. *channelsValidation*, *gtLabelsValidation*, ρυθμίσεις *batchsize_val_samples* κ.λπ.) και πόσο συχνά να εκτελείται πλήρης inference στο validation set.

Με τη σωστή ρύθμιση του *trainConfig.cfg*, το DeepMedic φορτώνει τα κατάλληλα δεδομένα, εφαρμόζει δειγματοληψία patches, ρυθμίζει τον βρόχο εκπαίδευσης και, αν ζητηθεί, εκτελεί περιοδικά validation για την εκτίμηση της απόδοσης.

testConfig.cfg

Χρησιμοποιείται στο στάδιο τελικής αξιολόγησης ή/και inference πάνω σε νέα δεδομένα. Περιλαμβάνει ρυθμίσεις που αφορούν τη φόρτωση των test samples και την αποθήκευση των αποτελεσμάτων:

- **sessionName** & **folderForOutput**
Το όνομα της συνεδρίας (session) και ο φάκελος όπου θα αποθηκευτούν οι προβλέψεις, τα log files και οι πιθανότητες.
- **channels**
Αρχεία κειμένου για τα modalities του test set. Εάν υπάρχουν πολλαπλά κανάλια (T1, T1c, T2, FLAIR), συμπεριλαμβάνονται όλα σε μορφή λίστας.
- **gtLabelsTest** (προαιρετικό)
Αν υπάρχει ground truth για το test set, μπορούμε να το ορίσουμε για εσωτερική αξιολόγηση των τελικών αποτελεσμάτων.

- **namesForPredictionsPerCaseTest**

Κατάλογος με ονόματα των ασθενών ή κωδικούς, για να γίνει αντιστοίχιση ανάμεσα στα input δεδομένα και στα αρχεία εξόδου (segmentation maps, probability maps).

- **numberTestSegmentsLoadedOnGpuPerSubep, batchsize_test_samples, batchsize_test_whole**

Ρυθμίσεις που ελέγχουν πόσα patches θα φορτώνονται στη GPU και τι μέγεθος batch θα χρησιμοποιείται για δειγματοληπτική ή πλήρη (whole-volume) πρόβλεψη.

- **saveSegmentationTest & saveProbMapsForEachClassTest**

Αν θα αποθηκεύονται οι τελικές τμηματοποιήσεις (.nii.gz) και οι χάρτες πιθανοτήτων, καθώς και για ποιες κλάσεις θα διατηρούμε τα αποτελέσματα.

- **run_input_checks, padInputImagesBool, norm_verbosity_lvl, norm_zscore_prms**

Επιπλέον ρυθμίσεις προκαταρκτικής επεξεργασίας και ελέγχου για τις εισόδους (παρόμοιες με εκείνες του *trainConfig.cfg*).

Εκτέλεση του DeepMedic

Αφού δημιουργήσουμε τα channel lists και ρυθμίσουμε τα αρχεία .cfg, μπορούμε να ξεκινήσουμε την εκπαίδευση με μια εντολή τύπου:

```
deepMedicRun \      -model /path/to/modelConfig.cfg \      -train /path/to/trainConfig.cfg \      -dev cuda0
```

- Το -model παραπέμπει στο modelConfig.cfg.
- Το -train στο trainConfig.cfg.
- Το -dev cuda0 καθορίζει ότι θα αξιοποιήσουμε την κάρτα γραφικών που φαίνεται ως “cuda0”.

Εφόσον υπάρχει ρύθμιση για validation, το δίκτυο θα εκτελεί αυτόματα ένα validation βήμα ανά μερικές εποχές (epochs), μετρώντας την επίδοση στις αντίστοιχες ετικέτες του validation set.

Κοινά Προβλήματα & Τρόποι Αντιμετώπισης

1. Λανθασμένες Διαδρομές στα .txt

Αν κάποια γραμμή στο `channelsTrain_T1.txt` ή στο `gtLabelsTrain.txt` είναι λάθος, το DeepMedic αδυνατεί να εντοπίσει το αρχείο, οπότε προκύπτει `FileNotFoundException`.

Η λύση είναι ο έλεγχος ότι οι διαδρομές του κάθε `.txt` συμπίπτουν με την πραγματική δομή φακέλων και ομοίως ότι όλες οι λίστες (T1, T1c, T2, FLAIR, labels) έχουν ακριβώς **τον ίδιο αριθμό** γραμμών.

2. **Ασυμφωνία στη Σειρά των Ασθενών**

Αν, για παράδειγμα, το αρχείο του T1 έχει πρώτη γραμμή το `Subject_001`, ενώ στο αρχείο labels η πρώτη γραμμή αφορά το `Subject_002`, το δίκτυο τροφοδοτεί λάθος δεδομένα στην εκπαίδευση.

Για να αποφύγουμε αυτό το σφάλμα, φροντίζουμε τα `scripts` που δημιουργούν τα `.txt` να ταξινομούν πάντα τους ασθενείς με την ίδια ακριβώς μέθοδο.

3. **Remapping Ετικετών (4 → 3 κ.λπ.)**

Στο BraTS, κάποιες ετικέτες υπερβαίνουν τις προσδοκίες του DeepMedic, π.χ. η τιμή 4. Γι' αυτό μπορεί να χρειαστεί τροποποίηση των τιμών (π.χ. αντικατάσταση της τιμής 4 με 3), πριν από τη διαδικασία εκπαίδευσης.

Αυτή η τροποποίηση γίνεται με εξωτερικά `scripts` που φορτώνουν τα αρχεία ετικετών, αλλάζουν τις τιμές και τα αποθηκεύουν σε νέα αρχεία `.nii.gz`.

4. **Διαχείριση Μνήμης και Μέγεθος Patches**

Το DeepMedic λειτουργεί με patches 3D· αν οι διαστάσεις τους είναι μεγάλες ή το batch size είναι υψηλό, εμφανίζεται σφάλμα `CUDA out of memory`.

Για να το αντιμετωπίσουμε, μειώνουμε το `patchDim` σε πιο διαχειρίσιμα μεγέθη ή ελαττώνουμε το `batchSize` (π.χ. σε 2), ανάλογα με τη VRAM που διαθέτουμε.

5. **Λανθασμένες Ρυθμίσεις σε .cfg**

Αν οι παράμετροι στα αρχεία ρυθμίσεων δεν ταιριάζουν με τον τύπο των δεδομένων (π.χ. ζητάμε 5 κανάλια εισόδου αντί για 4), το μοντέλο “σπάει” κατά την εκκίνηση.

Πρέπει να επιβεβαιώνουμε ότι ο αριθμός των modalities (channels) που ορίζουμε στο `modelConfig.cfg` ή `trainConfig.cfg` αντιστοιχεί ακριβώς στα αρχεία `.txt` που του δίνουμε.

Συνοπτική Ροή Προετοιμασίας στο DeepMedic

1. **Δημιουργούμε φακέλους** train/, validation/ (και test/ αν χρειάζεται) μέσα σε ένα κεντρικό directory (π.χ. deepmedic_data/).
2. **Μεταφέρουμε** όλες τις MRI τομογραφίες των ασθενών στους αντίστοιχους φακέλους, μαζί με τα αρχεία ετικετών (labels.nii.gz).
3. **(Προαιρετικά) Εκτελούμε remapping ετικετών**, αν το BraTS έχει ετικέτες που δεν συμβαδίζουν με το δίκτυο (π.χ. $4 \rightarrow 3$).
4. **Δημιουργούμε τα channel lists** (ένα .txt ανά modal) και ένα ακόμα .txt με τις ετικέτες (ground truth) για το train set, και αντίστοιχα για το validation set.
5. **Ρυθμίζουμε** τα αρχεία .cfg (modelConfig.cfg, trainConfig.cfg κ.λπ.), ώστε να “δείχνουν” στα σωστά .txt και να έχουν λογικές τιμές παραμέτρων (π.χ. patch size, batch size).
6. **Εκτελούμε την εκπαίδευση** με την εντολή deepMedicRun που ορίζει τα μονοπάτια των .cfg αρχείων και τη συσκευή (GPU) που θα χρησιμοποιηθεί.

Συμπεράσματα

Με την ολοκλήρωση αυτής της διαδικασίας, το DeepMedic θα φορτώσει σωστά τα δεδομένα, θα δημιουργήσει patches και θα ξεκινήσει να εκπαιδεύει το συνελκτικό νευρωνικό δίκτυο. Εάν ακολουθήσουμε προσεκτικά τα παραπάνω βήματα, μειώνουμε δραστηκά τα κοινά σφάλματα (π.χ. διαδρομών, ασυμφωνίας στη σειρά των ασθενών ή υπέρβασης μνήμης) και εξασφαλίζουμε ομαλή ροή προς την εκπαίδευση, την αξιολόγηση και, τελικώς, τη δημιουργία αξιόπιστων μοντέλων για την τρισδιάστατη τμηματοποίηση όγκων εγκεφάλου.

TransBTS




Figure 5

Το **TransBTS** αποτελεί ένα υβριδικό τρισδιάστατο μοντέλο τμηματοποίησης, το οποίο συνδυάζει Convolution neural networks (CNNs) με μετασχηματιστές (Transformers). Προκειμένου να λειτουργήσει ορθά, απαιτεί συγκεκριμένη δομή φακέλων, σωστή προεπεξεργασία και κατάλληλη ρύθμιση του περιβάλλοντος εκπαίδευσης.

Εισαγωγή & Διάρθρωση Δεδομένων

Ξεκινώντας με το σύνολο δεδομένων BraTS_2020, το οποίο περιλαμβάνει τέσσερις ακολουθίες (T1, T1ce, T2, FLAIR) καθώς και το αρχείο τμηματοποίησης όγκου (_seg.nii.gz). (Table 1) Η συνήθης διάρθρωση για κάθε ασθενή έχει τη μορφή:

```
0 | BraTS20_Training_XXX/
1 |   ├── BraTS20_Training_XXX_t1.nii.gz
2 |   ├── BraTS20_Training_XXX_t1ce.nii.gz
3 |   ├── BraTS20_Training_XXX_t2.nii.gz
4 |   ├── BraTS20_Training_XXX_flair.nii.gz
5 |   └── BraTS20_Training_XXX_seg.nii.gz
```

Table 3

Το TransBTS αναμένει τα δεδομένα οργανωμένα σε φακέλους. Σε αυτή την περίπτωση τα δεδομένα έχουν οργανωθεί σε δυο φακέλους “train/” και ένας ακόμα που περιέχει τα “Valid&Test/” δεδομένα. Επιπρόσθετα υπάρχουν και ξεχωριστά αρχεία κειμένου που περιέχουν τα paths των δεδομένων μέσα στους αντιστοίχους φακέλους. Στην παρούσα εργασία δημιουργήθηκε φάκελος train/ για τα δείγματα εκπαίδευσης, και τοποθετήθηκαν σε αυτόν τα σχετικά αρχεία μαζί με ένα αρχείο train.txt. Αναλόγως, δημιουργήθηκαν και κατάλογοι για το validation και το test, περιλαμβάνοντας 79 περιπτώσεις για επικύρωση και 46 για δοκιμή, με τα αντίστοιχα αρχεία valid.txt και test.txt. (Table 2) Η προσεκτική τήρηση της ονοματοδοσίας διασφαλίζουν τη σωστή λειτουργία των επόμενων βημάτων.

```
0 | TransBTS_data/
1 |   ├── Train/
2 |   |   ├── BraTS20_Training_292/
3 |   |   ├── BraTS20_Training_293/
```

4			└ ...
5			└ train.txt
6			└ valid_and_Test/
7			└ BraTS20_Validation_001
8			└ ...
9			└ valid.txt
10			└ test.txt

Table 4

Προεπεξεργασία Δεδομένων (*preprocess.py*)

Το TransBTS παρέχει συνήθως ένα αρχείο `preprocess.py`, αυτό αποτελεί το ενσωματωμένο στάδιο προεπεξεργασίας που παρέχεται μαζί με το μοντέλο (π.χ. TransBTS). Μέσω αυτού του script υλοποιούνται τα παρακάτω βήματα, τα οποία εξασφαλίζουν ότι τα δεδομένα είναι σε κατάλληλη μορφή πριν εισαχθούν στη διαδικασία εκπαίδευσης ή αξιολόγησης.

– Φόρτωση αρχείων NIfTI.

Διαβάζονται οι διαφορετικές απεικονίσεις (T1, T1ce, T2, FLAIR) για κάθε ασθενή, καθώς και το αντίστοιχο αρχείο τμηματοποίησης

– Κανονικοποίηση (Normalization)

Εφαρμόζεται z-score κανονικοποίηση εντός του εγκεφαλικού μασκ (brain mask). Το brain mask ορίζεται από τα voxels που έχουν μη μηδενικές τιμές στο άθροισμα όλων των modalities. Για καθένα από τα T1, T1ce, T2, FLAIR υπολογίζονται μέσος όρος και τυπική απόκλιση, και στη συνέχεια οι τιμές κανονικοποιούνται σε μέσο όρο 0 και διακύμανση 1.

– Διόρθωση και Επεξεργασία label

Ορισμένα αρχεία τμηματοποίησης ενδέχεται να περιέχουν την τιμή 4, η οποία αντικαθίσταται από 3 για να τηρηθεί η σωστή κατηγοριοποίηση (0–3). Με αυτόν τον τρόπο αποφεύγονται σφάλματα κατά το one-hot encoding, ειδικά όταν ορίζεται “num_class=4”.

– Αποθήκευση σε Ενιαίο Μορφότυπο

Το μοντέλο απαιτεί ότι τα τελικά δεδομένα θα αποθηκεύονται σε αρχεία .pkl, επιτρέποντας ταχύτερη φόρτωση κατά την εκπαίδευση. Επιπλέον, στο `preprocess.py` γίνο-

νται απαραίτητες ρυθμίσεις τον paths (root) και δηλώνεται ποιο αρχείο κειμένου περιλαμβάνει τις λίστες ασθενών (flist).

Αρχεία Κειμένου (*train.txt*, *valid.txt*, *test.txt*)

Το TransBTS αξιοποιεί αρχεία κειμένου που περιέχουν τα ονόματα ή τις διαδρομές των περιστατικών προς εκπαίδευση/επιβεβαίωση/δοκιμή. Για παράδειγμα, το αρχείο train.txt μπορεί να περιλαμβάνει:

0		BraTS20_Training_292
1		BraTS20_Training_293
2		BraTS20_Training_294
3		...

Table 5

Κατά την εκτέλεση, το λογισμικό φορτώνει αυτά τα ονόματα, αναζητά τα αντίστοιχα αρχεία (π.χ. t1.nii.gz, t1ce.nii.gz, t2.nii.gz, flair.nii.gz, _seg.nii.gz) και ξεκινά τη διαδικασία προεπεξεργασίας ή εκπαίδευσης. Για να εντοπίσει τα αρχεία συνδυάζει το root path με τα ονόματα μέσα στα αντίστοιχα αρχεία κειμένου.

Διαχείριση Περιβάλλοντος (*Multi-GPU* ή *Μονή GPU*)

Το κύριο σενάριο εκπαίδευσης του TransBTS συνήθως υποστηρίζει distributed training μέσω torch.distributed.launch. Σε περιπτώσεις εκτέλεσης σε μία μόνο GPU, συχνά εμφανίζονται σφάλματα όπως “unrecognized arguments: --local-rank=0”, απαιτώντας απενεργοποίηση του DistributedDataParallel μέσα στον κώδικα ή απλή εκτέλεση του train.py με ορίσματα όπως --gpus=0.

Προσθήκη Επιπρόσθετων Μετρικών Αξιολόγησης

Σε προεπιλεγμένες εκδόσεις του TransBTS, η μόνη αναφορά στη βελτίωση του μοντέλου βασίζεται σε τιμές loss. Αυτή η μεμονωμένη μέτρηση δεν προσφέρει πλήρη εικόνα της ακρίβειας τμηματοποίησης. Για τον λόγο αυτό, ενσωματώνονται συχνά επιπρόσθετες μετρικές, όπως Dice Similarity Coefficient (DSC), Accuracy, Sensitivity και Precision, οι οποίες παρέχουν κλινικά πιο ερμηνεύσιμη αξιολόγηση και επιτρέπουν καλύτερη ανίχνευση φαινομένων όπως το overfitting ή η ελλιπής ταξινόμηση περιοχών με μικρή αναπαράσταση.

Εκτέλεση του TransBTS

Αφού έχουμε ολοκληρώσει την προεπεξεργασία των δεδομένων (μέσω του script `preprocess.py`) και διασφαλίσουμε την ορθή οργάνωση τους στους φακέλους `Train/`, `Valid/` και `Test/` (καθώς και τη δημιουργία των αντίστοιχων αρχείων κειμένου, π.χ. `train.txt` και `valid.txt`), μπορούμε να ξεκινήσουμε την εκπαίδευση του μοντέλου TransBTS.

Για την εκπαίδευση του μοντέλου, εκτελούμε το βασικό script `train.py` με τις κατάλληλες παραμέτρους. Για παράδειγμα, μια τυπική εντολή μπορεί να είναι:

```
python3 train.py \
  --gpu 0 \
  --root /path/to/BraTs_Data \
  --train_dir Train \
  --train_file /path/to/all.txt \
  --valid_file /path/to/valid.txt \
  --batch_size 1 \
  --end_epoch 700
```

Table 6

- `--gpu 0`: Καθορίζει τη χρήση της GPU με δείκτη 0 (δηλαδή `cuda0`) για την επιτάχυνση των υπολογισμών κατά την εκπαίδευση.
- `--root`: Ορίζει τη βασική διαδρομή στα δεδομένα εκπαίδευσης. Στην περίπτωση αυτή, το μονοπάτι οδηγεί στον φάκελο που περιέχει το σύνολο δεδομένων BraTS2020 Training Data.
- `--train_dir`: Δηλώνει τον υποφάκελο εντός του `root` που περιέχει τα δεδομένα εκπαίδευσης (π.χ., `Train`).
- `--train_file`: Παραπέμπει στο αρχείο κειμένου (π.χ., `all.txt`) που περιέχει τα ονόματα ή τα πλήρη `paths` των φακέλων ασθενών που θα χρησιμοποιηθούν για την εκπαίδευση.
- `--valid_file`: Ορίζει το αρχείο κειμένου που περιέχει τα ονόματα ή τις διαδρομές των φακέλων για το `validation set`.
- `--batch_size 1`: Ορίζει το μέγεθος της παρτίδας σε 1, κάτι συνηθισμένο για 3D μοντέλα με υψηλές απαιτήσεις GPU μνήμης.
- `--end_epoch 700`: Ορίζει τον συνολικό αριθμό εποχών εκπαίδευσης σε 700.

Κατά τη διάρκεια της εκπαίδευσης, το TransBTS:

- Διαβάζει τα δεδομένα σύμφωνα με τις παραπάνω ρυθμίσεις.
- Υπολογίζει και καταγράφει όχι μόνο την απώλεια (loss), αλλά και επιπλέον μετρικές όπως Dice, Accuracy, Sensitivity και Precision.
- Πραγματοποιεί αυτόματα validation σε προκαθορισμένα διαστήματα (π.χ., κάθε epoch ή κάθε ορισμένες iterations), ώστε να αξιολογεί την πρόοδο και να ανιχνεύει πιθανά προβλήματα όπως το overfitting.

Η ενσωμάτωση των επιπρόσθετων μετρικών αξιολόγησης εξασφαλίζει μια πληρέστερη εικόνα της απόδοσης του μοντέλου, επιτρέποντας σύγκριση διαφορετικών παραμετροποιήσεων και την έγκαιρη ανίχνευση τυχόν δυσλειτουργιών κατά την εκπαίδευση.

Αντιμετώπιση Σφαλμάτων Κατά την Εκπαίδευση

Ένα συχνό σφάλμα που μπορεί να εμφανιστεί κατά την πρώτη εκτέλεση είναι το “CUDA error: device-side assert triggered”. Αυτό οφείλεται συνήθως σε αναντιστοιχίες μεταξύ των πραγματικών τιμών ετικετών και του εύρους που περιμένει το μοντέλο (π.χ. τιμή 4 όταν το εύρος είναι 0–3). Με την κατάλληλη λογική ελέγχου και αντικατάστασης τιμών ετικετών εντός του preprocess.py, εξασφαλίζεται ότι τα δεδομένα σέβονται τα όρια num_class=4. Τυχόν εντοπισμός τιμής 4 ενεργοποιεί άμεση αντικατάστασή της με 3, ώστε το μοντέλο να μη συναντήσει μη αποδεκτές κατηγορίες. Ομοίως, κατά τον υπολογισμό των μετρικών (π.χ. Dice, sensitivity, precision) πρέπει να επιβεβαιώνεται η ορθότητα και οι διαστάσεις των tensors.

Συμπεράσματα

Η διαδικασία εκτέλεσης του TransBTS περιλαμβάνει ένα σαφές στάδιο προεπεξεργασίας, την ορθή οργάνωση των δεδομένων και τη ρύθμιση των αρχείων κειμένου, με κύριο στόχο τη φόρτωση και κανονικοποίηση των απεικονίσεων, καθώς και τη διόρθωση των τιμών ετικετών. Επιπλέον, η διαχείριση του περιβάλλοντος (μονο-GPU ή Multi-GPU) και η ενσωμάτωση νέων μετρικών (Dice, Accuracy κ.ά.) αποτελούν βασικά βήματα για την επιτυχή και αξιόπιστη εκπαίδευση του μοντέλου. Οι επιπρόσθετες μετρικές επιτρέπουν μία πιο κλινικά ερμηνεύσιμη εκτίμηση της απόδοσης, ενώ η επιδιόρθωση κοινών σφαλμάτων, όπως το “device-side assert triggered”, εξασφαλίζει μια ομαλή και συνεπή διαδικασία μάθησης.

U – NET




Figure 6

Παρακάτω περιγράφεται η **διαδικασία προετοιμασίας δεδομένων για ένα U-Net** μοντέλο με σκοπό την εκπαίδευση τρισδιάστατης τμηματοποίησης σε δεδομένα BraTS. Η προσέγγιση U-Net βασίζεται συνήθως σε απλούστερη διαχείριση εισόδων σε σχέση με μοντέλα που απαιτούν εκτενείς “channel lists” ή πολυάριθμα configuration files. Ωστόσο, υπάρχουν συγκεκριμένες συστάσεις και βέλτιστες πρακτικές που βοηθούν στην ομαλή ροή της εκπαίδευσης.

Οργάνωση Φακέλων & Δεδομένων

Για την εκπαίδευση ενός 3D U-Net, είναι σύνηθες να διατηρούμε μία ενιαία δομή με φακέλους train/, validation/, και ενδεχομένως test/, όπου κάθε ασθενής έχει τα απαραίτητα αρχεία του:

```
0 | unet_data/
1 |   └─ train/
2 |     └─ Subject_001/
3 |       └─ Subject_001_t1.nii.gz
4 |       └─ Subject_001_t1ce.nii.gz
5 |       └─ Subject_001_t2.nii.gz
6 |       └─ Subject_001_flair.nii.gz
```

```

7 |   |   |   └─ Subject_001_seg.nii.gz
8 |   |   └─ Subject_002/
9 |   |   └─ ...
10|   └─ validation/
11|   |   └─ ...
12|   └─ test/
13|       └─ ...
14|

```

Table 7

- Ονοματοδοσία: Συχνά ακολουθούμε ένα τυποποιημένο μοτίβο, π.χ. Subject_XXX_t1.nii.gz, Subject_XXX_t1ce.nii.gz, κ.ο.κ., ώστε να αναγνωρίζονται εύκολα οι διαφορετικές ακολουθίες.
- Ground Truth Ετικέτες: Χρησιμοποιούμε ένα τυποποιημένο suffix όπως _seg.nii.gz για τη μάσκα του όγκου.

Αν η υλοποίηση του U-Net χρησιμοποιεί κάποια **βιβλιοθήκη** (π.χ. MONAI ή nnU-Net), η βιβλιοθήκη μπορεί να έχει πιο αυστηρές οδηγίες για τη δομή φακέλων ή το naming. Για παράδειγμα, το nnU-Net συχνά απαιτεί αρχεία με όνομα xxxxx_0000.nii.gz, xxxxx_0001.nii.gz, κ.λπ. Σε αυτή την περίπτωση, χρειάζεται να μετονομάζονται τα αρχεία ανά modal.

Προεπεξεργασία & Κανονικοποίηση

Το U-Net δέχεται συνήθως ως είσοδο ένα πολυκαναλικό (multichannel) 3D tensor, όπου οι διαφορετικές ακολουθίες (T1, T1ce, T2, FLAIR) στοιβάζονται διαστασιακά. Για παράδειγμα, μπορεί να έχουμε σχήμα (4, 240, 240, 155) εάν συνδυάσουμε σε μία μεταβλητή PyTorch τις τέσσερις MRI ακολουθίες:

1. Κανονικοποίηση Εντάσεων:

- Είναι σύνηθες να εφαρμόζονται τεχνικές z-score (αφαίρεση του μέσου, διαίρεση με την τυπική απόκλιση) ή min-max scaling. Αυτό μπορεί να γίνει on-the-fly όταν φορτώνονται τα δεδομένα ή εκ των προτέρων, δημιουργώντας ενδιάμεση μορφή αρχείων.

1. Cropping / Resizing:

- Τα αρχεία BraTS είναι μεγάλων διαστάσεων (π.χ. 240×240×155). Εάν η διαθέσιμη GPU μνήμη είναι περιορισμένη, γίνεται cropping σε μικρότερο ορθογώνιο

παραλληλεπίπεδο (π.χ. $128 \times 128 \times 128$) ή χρήση “patch-based” εκπαίδευσης, ώστε να αποφευχθεί σφάλμα out-of-memory.

1. **Remapping Ετικετών:**

- Παρόμοια με άλλα μοντέλα, αν οι ετικέτες υπερβαίνουν την αναμενόμενη κλίμακα (π.χ. τιμή 4 στο BraTS), μπορεί να χρειαστεί να επανχαρτογραφηθούν ($4 \rightarrow 3$). Αυτό διασφαλίζει ότι το U-Net δεν υποθέτει κατηγορίες που δεν υπάρχουν (ή είναι εκτός του επιθυμητού φάσματος).

Διαχείριση και Φόρτωση των Δεδομένων

Ανάλογα με τον κώδικα του U-Net ή τη βιβλιοθήκη που χρησιμοποιούμε, η φόρτωση των δεδομένων γίνεται με:

- **DataLoader** σε PyTorch, όπου ορίζουμε:
- Μια λίστα ή έναν πίνακα με τις διαδρομές προς τα αρχεία (input) και τις διαδρομές προς τα αντίστοιχα αρχεία ετικετών (labels).
- Μια κλάση Dataset που φορτώνει τα αρχεία (.nii.gz) και τα επιστρέφει ως (input_tensor, label_tensor).
- **CSV/JSON με λίστες περιστατικών:**
- Μερικά frameworks επιτρέπουν τη χρήση ενός CSV με στήλες, π.χ. “T1 path”, “T1ce path”, “T2 path”, “FLAIR path”, “Label path”, μία γραμμή ανά ασθενή.
- Το DataLoader διαβάζει αυτή τη λίστα και αυτόματα φορτώνει τις εικόνες, ετοιμάζοντάς τις για το μοντέλο.
- **nnU-Net ειδικά**:****
- Το nnU-Net περιμένει πιο συγκεκριμένη ονοματοδοσία (π.χ. Case_001_0000.nii.gz = κανάλι 0, Case_001_0001.nii.gz = κανάλι 1, ..., Case_001_seg.nii.gz = ετικέτες), και έναν φάκελο “imagesTr” για training, “labelsTr” για τα labels κ.λπ. Σε αυτή την περίπτωση, ακολουθούμε πιστά τις οδηγίες της nnU-Net για να γίνει η αυτόματη παραμετροποίηση.

Εκπαίδευση & Hyperparameters

Για ένα 3D U-Net, υπάρχουν ορισμένες παράμετροι που επηρεάζουν τη διαδικασία εκπαίδευσης:

1. **Batch Size:**

- Συνήθως κρατιέται πολύ χαμηλό (1–2), λόγω των υψηλών απαιτήσεων μνήμης σε 3D δεδομένα.

- Αν γίνεται patch-based εκπαίδευση, το batch size μπορεί να αυξηθεί με μικρότερα patches.
2. **Learning Rate:**
 - Πολλά U-Net μοντέλα εκκινούν από τιμή γύρω στο $1e-3$ ή $1e-4$, αν και αυτό είναι βιβλιογραφικά εξαρτώμενο.
 3. **Loss Function:**
 - Χρησιμοποιείται συχνά Dice Loss ή συνδυασμός Dice + CrossEntropy. Ειδικά για την τμηματοποίηση όγκων, το Dice Loss έχει αποδειχθεί ιδιαίτερα αποτελεσματικό.
 4. **Augmentation:**
 - Επειδή οι 3D MRI τομογραφίες τείνουν να είναι περιορισμένες σε αριθμό, εφαρμόζονται τεχνικές data augmentation (περιστροφή, μετατόπιση, αυξομείωση κ.λπ.) on-the-fly μέσα στο DataLoader, για καλύτερη γενίκευση.

Κοινά Προβλήματα & Τρόποι Αντιμετώπισης

1. **Out-of-Memory (OOM) Σφάλματα:**
 - Το συχνότερο εμπόδιο σε 3D U-Net. Λύση: μικρότερα patches ή μικρότερο batch size.
2. **Λανθασμένη Συσχέτιση Εικόνων-Labels:**
 - Αν στο Dataset class αντιστοιχίσουμε T1 εικόνες του Subject_001 με seg του Subject_002, θα λάβουμε ασαφή αποτελέσματα ή σφάλματα. Προσοχή στη συνέπεια στη λίστα περιστατικών.
3. **Διαφορετικά Σχήματα:**
 - Οι τομογραφίες στο BraTS έχουν την ίδια θεωρητικά διάσταση ($240 \times 240 \times 155$), όμως σε κάποιες περιπτώσεις παλαιότερων εκδόσεων μπορεί να διαφέρουν. Αν υπάρχει ασυμβατότητα, απαιτείται είτε resizing (resample) είτε patch-based στρατηγική.
4. **Remapping Ετικετών:**
 - Όπως και στις άλλες αρχιτεκτονικές, αν υπάρχουν ετικέτες εκτός του υποστηριζόμενου εύρους (π.χ. τιμή 4), χρειάζεται remapping ($4 \rightarrow 3$ ή όπως κρίνουμε).
5. **Mismatch Λογισμικών:**
 - Εάν χρησιμοποιούμε βιβλιοθήκες όπως το MONAI ή το nnU-Net, πρέπει να βεβαιωθούμε ότι είναι συμβατές οι εκδόσεις (PyTorch, SimpleITK κ.ο.κ.). Διαφο-

ρετικά, σφάλματα τύπου “module not found” ή ασυμβατότητας απαντώνται συχνά.

Συνοπτική Ροή Ρυθμίσεων για U-Net

1. **Ομάδα Φακέλων:** δημιουργούμε ή χωρίζουμε τα δεδομένα σε train/, validation/, (προαιρετικά test/). Σε κάθε folder, κάθε ασθενής έχει τα αρχεία `t1.nii.gz`, `t1ce.nii.gz`, `t2.nii.gz`, `flair.nii.gz`, `seg.nii.gz`.
2. **(Προαιρετικά) Μετονομάζουμε** τα αρχεία σύμφωνα με τις οδηγίες του U-Net framework. Π.χ. για nnU-Net: `xxx_0000.nii.gz`, `xxx_0001.nii.gz`, κ.λπ.
3. **Διαμορφώνουμε** έναν Dataset μηχανισμό (σε PyTorch, MONAI ή άλλο), ο οποίος διαβάζει αυτά τα αρχεία, δημιουργεί πολυκαναλικό input (C=4 για T1, T1ce, T2, FLAIR) και φορτώνει την ετικέτα (seg).
4. **Κανονικοποίηση & Augmentation:** ανάλογα με τη μνήμη που διαθέτουμε, εφαρμόζουμε on-the-fly z-score, cropping, random rotations κ.λπ.
5. **Ρύθμιση Εκπαίδευσης:** ορίζουμε batch size (π.χ. 1–2), loss function (Dice Loss), και optimizer (συνήθως Adam).
6. **Εκκίνηση Training:** τρέχουμε το κεντρικό training script. Παρακολουθούμε μετρικές (Dice, Hausdorff distance), logs, και checkpoints.

Τελικό Σχόλιο

Η προετοιμασία δεδομένων για το U-Net μπορεί να θεωρηθεί πιο ευέλικτη σε σχέση με άλλα μοντέλα που χρησιμοποιούν συγκεκριμένα configuration files ή channel lists. Ωστόσο, η επιτυχία εξαρτάται από:

- Τη συνεπή ονοματοδοσία (ώστε να είναι εφικτή η διασταύρωση των ακολουθιών με τις ετικέτες).
- Τη σχολαστική κανονικοποίηση (για να διατηρείται σταθερή η κλίμακα των εντάσεων).
- Την προσεκτική χρήση patch-based εκπαίδευσης (εφόσον τα δεδομένα είναι μεγάλη και η GPU περιορισμένη).

Ακολουθώντας τις παραπάνω αρχές, το U-Net αξιοποιεί αποτελεσματικά τα 3D δεδομένα BraTS, προσφέροντας σαφή και αξιόπιστη τμηματοποίηση όγκων εγκεφάλου.

ViT




Figure 7

Παρακάτω παρουσιάζεται η διαδικασία προετοιμασίας δεδομένων για την εκπαίδευση ενός **Vision Transformer (ViT)** σε τρισδιάστατες (3D) ιατρικές εικόνες, με έμφαση στο σύνολο δεδομένων BraTS. Η οικογένεια των ViT μοντέλων διαφέρει από τα κλασικά CNN στο ότι βασίζεται σε μετασχηματιστές (Transformers) και τη μετατροπή των εικόνων σε αλληλουχίες “patch tokens”. Στην περίπτωση των 3D δεδομένων, αυτό συνεπάγεται επιπρόσθετες απαιτήσεις όσον αφορά τη διαχείριση της χωρικής ανάλυσης και τον πιθανό τεμαχισμό της εικόνας σε μικρότερα τμήματα (patches).

Οργάνωση Φακέλων & Εισόδων

Όπως και με άλλα μοντέλα, το πρώτο βήμα είναι η οργανωμένη διάταξη των δεδομένων BraTS σε φακέλους. Διατηρούμε συνήθως μια δομή με train/, validation/ και (προαιρετικά) test/, τοποθετώντας μέσα σε καθέναν τους φακέλους ασθενών:

```
0 | vit_data/
1 |   └─ train/
2 |     └─ Subject_001/
3 |       └─ Subject_001_t1.nii.gz
```

```

4 | | | | Subject_001_t1ce.nii.gz
5 | | | | Subject_001_t2.nii.gz
6 | | | | Subject_001_flair.nii.gz
7 | | | | Subject_001_seg.nii.gz
8 | | | | ...
9 | | | validation/
10| | | | ...
11| | | test/
12| | | ...
13|

```

Table 8

Η λογική είναι παρόμοια με αυτήν στο U-Net, αλλά στα ViT δίκτυα υπολογίζεται συχνά μια “patchification” φάση.

Πολυκαναλικές Εικόνες & Μετατροπή σε Tokens

Σε 3D Vision Transformers, συναντώνται δύο βασικές προσεγγίσεις:

1. On-the-fly tokenization:

- Κατά τη φόρτωση των δεδομένων, το πρόγραμμα χωρίζει τον όγκο σε μικρά 3D patches. Για παράδειγμα, αν η είσοδος είναι (C=4, H=240, W=240, D=155), μπορούμε να την “κόψουμε” σε μικρότερα κυβικά blocks (π.χ. 16×16×16). Κάθε block αναδιοργανώνεται ως ένα token για το μοντέλο Transformer.
- Αυτή η διαδικασία γίνεται δυναμικά σε κάθε batch μέσω ενός PyTorch DataLoader ή κάποιας βιβλιοθήκης. Προϋποθέτει ότι έχουμε αρκετή υπολογιστική ισχύ για να εκτελούμε το slicing και την προεπεξεργασία σε πραγματικό χρόνο.

2. Preprocessing scripts που παράγουν “patch-based” αρχεία:

- Κάποιες υλοποιήσεις ViT απαιτούν να έχουμε εκ των προτέρων μετατρέψει τα δεδομένα σε patches ή ακόμα και να τα αποθηκεύσουμε ως ξεχωριστά αρχεία (π.χ. .npy). Έτσι, αντί να φορτώνουμε ολόκληρο τον όγκο, φορτώνουμε μεμονωμένες “φέτες”/patches-τοκέν σε μορφή έτοιμη για το Transformer.
- Αυτό μειώνει το runtime overhead, αλλά απαιτεί περισσότερο χώρο αποθήκευσης και πιο σύνθετο σκριπτάρισμα (scripts) για την προετοιμασία.

Σε κάθε περίπτωση, η ιδέα είναι να **συνενώνονται** οι 4 ακολουθίες (T1, T1ce, T2, FLAIR) στον ίδιο όγκο, ο οποίος θεωρείται ότι έχει $C=4$. Το seg αρχείο φορτώνεται επίσης ως ξεχωριστή “μάσκα” (label).

Κανονικοποίηση & Resizing

Η χωρική ανάλυση $240 \times 240 \times 155$ ενδέχεται να είναι υπερβολική για ένα 3D ViT, καθώς τα Transformers έχουν υψηλές απαιτήσεις σε μνήμη, ιδίως αν το patch size είναι μικρό. Γι’ αυτό:

1. **Resizing / Resampling:** Μπορεί να μικρύνουμε ελαφρώς το μέγεθος σε $(128 \times 128 \times 128)$ για όλο τον εγκέφαλο ή να εφαρμόσουμε κάποιον τύπο cropping ώστε να εστιάσουμε στην περιοχή του όγκου.
2. **Z-score Normalisation:** Συνήθως εφαρμόζεται σε κάθε κανάλι (MRI ακολουθία) ξεχωριστά. Ο μέσος και η τυπική απόκλιση υπολογίζονται είτε στον ολόκληρο τόμο είτε σε μια προεπιλεγμένη ROI.
3. **Remapping ετικετών:** Σε περίπτωση που έχουμε ετικέτες τύπου 4 στο BraTS, τις επαναχарτογραφούμε σε 3, ώστε το μοντέλο να μην συγχέεται από μη αναμενόμενες τιμές.

Διαχείριση Δεδομένων & Φάκελος Config

Ανάλογα με την υλοποίηση του ViT:

- **Μπορεί** να υπάρχει ένα αρχείο ρυθμίσεων (config), όπου ορίζονται παραμέτρους όπως patch_size, embed_dim, num_heads κ.λπ., και οι διαδρομές προς τα train/validation δεδομένα.
- **Εναλλακτικά**, μπορούμε να έχουμε ένα script (π.χ. train_vit.py) που διαβάζει ένα CSV ή ένα JSON, στο οποίο σημειώνεται πού βρίσκονται τα πολλαπλά αρχεία (T1, T1ce, T2, FLAIR, seg). Ο κώδικας τα στοιβάζει σε έναν 4D όγκο ($C \times H \times W \times D$) και στη συνέχεια εφαρμόζει το tokenization.

Σημαντικό είναι να διασφαλίσουμε ότι το script που ορίζει τη φάση tokenization λαμβάνει υπόψη όλα τα κανάλια. Μερικά παραδείγματα ViT μοντέλων, αν έχουν φτιαχτεί αρχικά για μονοκαναλική είσοδο (π.χ. RGB=3 κανάλια σε 2D εικόνες), χρειάζονται τροποποιήσεις για 4 κανάλια 3D.

Εκπαίδευση & Υπολογιστικοί Πόροι

Τα 3D ViT δίκτυα έχουν συνήθως σημαντικά μεγαλύτερο αριθμό παραμέτρων σε σύγκριση με τα αντίστοιχα CNN. Έτσι, η κατανάλωση μνήμης μπορεί να είναι πολύ υψηλή. Πρακτικοί τρόποι αντιμετώπισης:

- **Μείωση του patch size:** Μεγαλύτερο patch size σημαίνει λιγότερους tokens, άρα λιγότερη μνήμη. Όμως, υπερβολικά μεγάλο patch size ίσως περιορίσει την ικανότητα του μοντέλου να διακρίνει λεπτομέρειες.
- **Batch size = 1:** Είναι πολύ συνηθισμένο να έχουμε batch size εξαιρετικά χαμηλό, καθώς ο κάθε όγκος (και τα tokens που παράγονται) απαιτεί πολύ χώρο.
- **Gradient checkpointing:** Τεχνική που επιτρέπει την αποθήκευση λιγότερων ενδιάμεσων ενεργοποιήσεων και επομένως μειώνει προσωρινά τη μνήμη που καταλαμβάνει το backward pass. Αυτό μπορεί να παρατείνει όμως τον χρόνο εκπαίδευσης.
- **Mixed Precision Training:** Χρήση των FP16 (ή άλλων τρόπων χαμηλής ακρίβειας), ώστε να μειωθεί ο συνολικός όγκος δεδομένων στη μνήμη GPU.

Κοινά Προβλήματα & Τρόποι Αντιμετώπισης

1. **“CUDA out of memory”:**
 - Πιο σύνηθες σε 3D ViT παρά σε CNN. Χρειάζεται προσεκτικός σχεδιασμός patch size, batch size, και πιθανή χρήση τεχνικών μεγιστοποίησης της μνήμης (gradient checkpointing).
2. **Ασυμφωνία στον Αριθμό Καναλιών:**
 - Ορισμένοι κώδικες ViT ξεκίνησαν για 2D images με 3 κανάλια (RGB). Αν τώρα έχουμε 4 κανάλια (T1, T1ce, T2, FLAIR), πρέπει να αλλάξουμε το κομμάτι που υπολογίζει τον “channel embedding”. Διαφορετικά, προκύπτει σφάλμα σχήματος tensor.
3. **Παραγκωνισμός Κλινικών Λεπτομερειών:**
 - Αν το patch size είναι πολύ μεγάλο, προκειμένου να μην παράγονται πολλοί tokens, μπορεί να μην απεικονίζονται επαρκώς λεπτές δομές. Χρειάζεται ισορροπία μεταξύ λεπτομέρειας και υπολογιστικού κόστους.
4. **Διαχείριση .txt ή CSV Λιστών:**
 - Η συνηθισμένη μέθοδος είναι να έχουμε ένα αρχείο που περιλαμβάνει τις διαδρομές προς το T1, T1ce, T2, FLAIR και seg για κάθε ασθενή. Το training script χωρίζει τα train/validation sets. Ανταγωνιστικές εκδόσεις ViT μπορεί να θέλουν συγκεκριμένη μορφή (π.χ. JSON).

5. **Non-rectangular Cropping:**

- Μερικά scripts εφαρμόζουν αυτόματο cropping πέριξ του όγκου, ώστε το ViT να επικεντρωθεί μόνο στη ζώνη ενδιαφέροντος. Αυτό μπορεί να βελτιώσει τη χρήση μνήμης και την ακρίβεια, αλλά απαιτεί προσεκτική ρύθμιση για να μην κοπούν σημαντικές περιοχές.

Συνοπτική Ροή Προετοιμασίας για ViT

1. **Οργάνωση:** Τοποθετούμε τα αρχεία `t1.nii.gz`, `t1ce.nii.gz`, `t2.nii.gz`, `flair.nii.gz`, `seg.nii.gz` σε φακέλους `train/validation/test`, ανά subject.
2. **Κανονικοποίηση & Remapping:** Ελέγχουμε ότι εφαρμόζονται κατάλληλοι μετασχηματισμοί εντάσεων (π.χ. z-score) και επαναχαρτογράφηση ετικετών (π.χ. $4 \rightarrow 3$).
3. **Tokenization:** Αν η λύση μας περιλαμβάνει on-the-fly tokenization, την ορίζουμε στον PyTorch DataLoader. Αν θέλουμε offline patches, δημιουργούμε σχετικά αρχεία.
4. **Ορισμός Ρυθμίσεων:** Ρυθμίζουμε `patch_size`, `embed_dim` κ.λπ. σε ένα config. Παρακολουθούμε πόσους tokens θα παράγουμε ανά όγκο, ώστε να μην ξεπεράσουμε τη GPU μνήμη.
5. **Έναρξη Εκπαίδευσης:** Τρέχουμε το script (`train_vit.py` ή παρεμφερές όνομα), ορίζοντας τις λίστες `train/val` και παρακολουθούμε τις μετρικές (π.χ. Dice).
6. **Έλεγχος Μνήμης:** Σε περίπτωση σφάλματος μνήμης, τροποποιούμε το `patch size` ή ενεργοποιούμε `mixed precision / gradient checkpointing`

4 Αποτελέσματα

Σε αυτό το κεφάλαιο παρουσιάζονται τα αποτελέσματα της πειραματικής αξιολόγησης των επιλεγμένων μοντέλων για την τρισδιάστατη τμηματοποίηση εγκεφαλικών όγκων. Στόχος αυτής είναι η μέτρηση της ακρίβειας, της γενίκευσης και της ικανότητας των συστημάτων AI να ενσωματωθούν σε κλινικά περιβάλλοντα.

Τα παρακάτω αποτελέσματα δεν θα παρουσιαστούν μόνο ως αριθμητικές τιμές, αλλά και μέσα από συγκριτικές εικόνες και διαγράμματα που αποδεικνύουν την πρακτική εφαρμογή και την ενσωμάτωση των μοντέλων στην κλινική διαδικασία. Η λεπτομερής ανάλυση των αποτελεσμάτων, που ακολουθεί στο επόμενο τμήμα, θα συμβάλει στην τεκμηρίωση αυτών και θα προσφέρει μια βάση για την εμπειριστατωμένη συζήτηση στο Κεφάλαιο 5, όπου θα αναλυθούν οι επιπτώσεις, τα δυνατά σημεία και οι περιορισμοί των προσεγγίσεων.

4.1 Αξιολόγηση και Σύγκριση των Μοντέλων

Σε αυτή την ενότητα παρουσιάζεται η συγκριτική αξιολόγηση των επιλεγμένων μοντέλων για την τρισδιάστατη τμηματοποίηση εγκεφαλικών όγκων, βάσει των παρακάτω μετρικών: training loss, validation loss, Dice score, precision, accuracy και sensitivity.

Ο παρακάτω πίνακας (Πίνακας 8) συνοψίζει τις τιμές των μετρικών για κάθε μοντέλο.

Μοντέλο	Training Loss	Validation Loss	Dice Score	Precision	Accuracy	Sensitivity
UNET	0.0228	0.0248	0.5461	0.9933	0.9917	0.9894
ViT			0.3628	0.9929	0.9863	0.9839
TransBTS	1.4499	1.5164	0.5166	0.4065		0.6835
Deep-Medic	1.2972	1.6142	0.4033	0.3442		0.4123

Table 8

4.1.1 UNET:

Loss: Το διάγραμμα απεικονίζει τη σταθερή μείωση του loss κατά την εκπαίδευση του UNET, φτάνοντας σε μια χαμηλή τιμή 0.0228 μετά από περίπου 120 εποχές. Αξιοσημείωτη είναι η ελάχιστη διαφορά μεταξύ training και validation loss (0.0248), υποδεικνύοντας καλή ικανότητα γενίκευσης χωρίς υπερπροσαρμογή (overfitting). Αυτό επιβεβαιώνει την αξιοπιστία της αρχιτεκτονικής U-Net ακόμη και χωρίς εφαρμογή τεχνικών επαύξησης δεδομένων.




Figure 8

Dice Score: Ο δείκτης Dice παρουσιάζει σταδιακή βελτίωση κατά την εκπαίδευση, φτάνοντας στην τελική τιμή 0.5461. Παρατηρούμε ότι μετά τις πρώτες 50 εποχές, ο ρυθμός βελτίωσης επιβραδύνεται, υποδηλώνοντας ότι το μοντέλο προσεγγίζει το βέλτιστο σημείο σύγκλισης. Η σχετικά υψηλή τιμή Dice υποδεικνύει καλή χωρική επικάλυψη μεταξύ των προβλεπόμενων τμηματοποιήσεων και των ground truth επισημάνσεων.




Figure 9

Precision: Η precision του UNET φτάνει την εξαιρετικά υψηλή τιμή 0.9933, υποδηλώνοντας ότι σχεδόν όλα τα voxel που ταξινομούνται ως όγκος, είναι όντως μέρος αυτού. Αυτό αποδεικνύει την ικανότητα του μοντέλου να αποφεύγει ψευδώς θετικές προβλέψεις, ένα κρίσιμο χαρακτηριστικό για κλινικές εφαρμογές όπου η ακρίβεια της οριοθέτησης είναι ουσιώδης για το σχεδιασμό χειρουργικών επεμβάσεων.




Figure 10

Accuracy: Με τιμή accuracy 0.9917, το UNET επιδεικνύει εξαιρετική συνολική απόδοση στην κατηγοριοποίηση των voxel. Η υψηλή ακρίβεια σε συνδυασμό με τον ικανοποιητικό δείκτη Dice, υποδηλώνει ότι το μοντέλο είναι αποτελεσματικό τόσο στην αναγνώριση των περιοχών του όγκου όσο και στην αποφυγή εσφαλμένων ταξινομήσεων του υγιούς ιστού.



Figure 11

Sensitivity: Η sensitivity 0.9894, δείχνει την εξαιρετική ικανότητα του UNET να εντοπίζει σχεδόν όλες τις περιοχές όγκου, αφήνοντας ελάχιστες περιοχές αδιάγνωστες. Ο συνδυασμός υψηλής sensitivity και precision καθιστά το UNET ένα αξιόπιστο εργαλείο για την ακριβή τμηματοποίηση όγκων, ειδικά σε περιπτώσεις όπου η ανίχνευση όλων των παθολογικών περιοχών είναι κρίσιμη για την κλινική απόφαση.




Figure 12

4.1.2 VIT:

Dice Score: Το μοντέλο Vision Transformer επιτυγχάνει δείκτη Dice 0.3628, που είναι χαμηλότερος από το UNET. Η διαφορά αυτή πιθανώς οφείλεται στην απουσία τεχνικών επαύξησης δεδομένων, καθώς οι Transformers τυπικά απαιτούν μεγαλύτερα σύνολα δεδομένων για αποτελεσματική εκπαίδευση. Παρατηρείται ωστόσο σταθερή σύγκλιση μετά από περίπου 80 εποχές.




Figure 13

Precision: Με τιμή precision 0.9929, το ViT παρουσιάζει εντυπωσιακή ακρίβεια στις θετικές του προβλέψεις, σχεδόν εφάμιλλη με το UNET. Αυτό υποδηλώνει ότι παρά τις διαφορές στο Dice score, το μοντέλο παραμένει αξιόπιστο στην αποφυγή ψευδώς θετικών αποτελεσμάτων, κάτι που αποτελεί σημαντικό πλεονέκτημα στο κλινικό περιβάλλον.




Figure 14

Accuracy: Η accuracy του ViT φτάνει το 0.9863, μια εξαιρετικά υψηλή τιμή που υποδηλώνει ότι το μοντέλο ταξινομεί σωστά την πλειονότητα των voxel. Αυτή η επίδοση είναι αξιοσημείωτη για ένα μοντέλο βασισμένο σε Transformer, που εφαρμόζεται σε τρισδιάστατα δεδομένα χωρίς επαύξηση.




Figure 15

Sensitivity: Με sensitivity 0.9839, το ViT καταφέρνει να εντοπίσει το μεγαλύτερο μέρος των περιοχών όγκου. Η υψηλή αυτή τιμή, σε συνδυασμό με την υψηλή precision, δείχνει ότι το μοντέλο είναι αποτελεσματικό στην αναγνώριση παθολογικών περιοχών, παρά τον σχετικά χαμηλότερο δείκτη Dice.




Figure 16

4.1.3 DeepMedic:

Dice Score: Το DeepMedic επιτυγχάνει δείκτη Dice 0.4033, μια μέση τιμή συγκριτικά με τα άλλα μοντέλα. Η καμπύλη παρουσιάζει αρκετές διακυμάνσεις καθώς εξελίσσεται η εκπαίδευση, υποδηλώνοντας πιθανή ευαισθησία του μοντέλου στην ποικιλομορφία των δεδομένων ή δυσκολία στη σύγκλιση χωρίς επιπλέον τεχνικές ομαλοποίησης.




Figure 17

Precision: Με χαμηλότερη τιμή precision στο 0.3442, το DeepMedic παρουσιάζει σημαντικά περισσότερες ψευδώς θετικές προβλέψεις συγκριτικά με τα άλλα μοντέλα. Αυτό δείχνει ότι η αρχιτεκτονική multi-scale του DeepMedic, ενδέχεται να χρειάζεται ισχυρότερη προεπεξεργασία δεδομένων για να επιτύχει υψηλότερη ακρίβεια στην τμηματοποίηση.




Figure 18

Sensitivity: Η τιμή sensitivity 0.4123, είναι επίσης χαμηλότερη συγκριτικά με τα άλλα μοντέλα, υποδηλώνοντας ότι το DeepMedic αφήνει αδιάγνωστες αρκετές περιοχές που ανήκουν στον όγκο. Αυτή η συμπεριφορά, σε συνδυασμό με τη χαμηλή precision, υποδεικνύει ότι το μοντέλο αντιμετωπίζει δυσκολίες στην ακριβή αναγνώριση των ορίων των όγκων, χωρίς επιπλέον βοηθητικές τεχνικές επεξεργασίας.




Figure 19

4.1.4 TransBTS:

Loss: Το διάγραμμα loss του TransBTS ξεκινά από υψηλή τιμή και μειώνεται σταδιακά, καταλήγοντας σε 1.4499 για το training και 1.5164 για το validation. Η διαφορά μεταξύ των δύο loss είναι σχετικά μικρή, υποδηλώνοντας καλή γενίκευση, αν και οι απόλυτες τιμές είναι υψηλότερες συγκριτικά με το UNET. Αυτό πιθανόν οφείλεται στην πολυπλοκότητα της υβριδικής αρχιτεκτονικής και στον μεγαλύτερο αριθμό παραμέτρων.




Figure 20

Dice Score: Με δείκτη Dice 0.5166, το TransBTS πετυχαίνει την υψηλότερη τιμή μεταξύ των τεσσάρων μοντέλων. Η καμπύλη δείχνει συνεχή βελτίωση μέχρι το τέλος της εκπαίδευσης, υποδηλώνοντας ότι το μοντέλο επωφελείται από τον συνδυασμό των ικανοτήτων των CNN για τοπικά χαρακτηριστικά και των Transformers για μακροπρόθεσμες συσχετίσεις.




Figure 21

Precision: Η τιμή precision 0.4065 είναι χαμηλότερη από αυτή των UNET και ViT, αλλά υψηλότερη από του DeepMedic. Αυτό υποδηλώνει ότι το TransBTS παράγει περισσότερες ψευδώς θετικές προβλέψεις, αν και όχι τόσες όσες το DeepMedic. Η μέτρια precision σε συνδυασμό με τον υψηλό δείκτη Dice δείχνει ότι το μοντέλο επιτυγχάνει καλή συνολική επικάλυψη, παρά τις λιγότερο ακριβείς προβλέψεις σε κάποιες περιοχές.




Figure 22

Sensitivity: Το TransBTS επιτυγχάνει sensitivity 0.6835, τιμή χαμηλότερη από τα UNET και ViT αλλά σημαντικά υψηλότερη από το DeepMedic. Αυτό δείχνει ότι το μο-

ντέλο αναγνωρίζει ένα σημαντικό μέρος των περιοχών του όγκου, αν και όχι με την ίδια πληρότητα όπως τα UNET και ViT. Η ισορροπία μεταξύ μέτριας precision και σχετικά υψηλής sensitivity υποδηλώνει ότι το TransBTS τείνει να συμπεριλαμβάνει περισσότερες περιοχές στις προβλέψεις του, αυξάνοντας την ευαισθησία εις βάρος της ακρίβειας.




Figure 23

4.2 Συγκριτική ανάλυση όλων των μοντέλων:

Συγκρίνοντας τις επιδόσεις των τεσσάρων μοντέλων, παρατηρούμε ότι το UNET επιτυγχάνει τις βέλτιστες τιμές στις περισσότερες μετρικές, με εξαιρετικά υψηλή precision και sensitivity, επιβεβαιώνοντας τη σταθερότητα της αρχιτεκτονικής encoder-decoder σε εφαρμογές τμηματοποίησης ιατρικών εικόνων. Το TransBTS ακολουθεί με παρόμοιο δείκτη Dice, αλλά χαμηλότερες τιμές precision και sensitivity, αναδεικνύοντας την αποτελεσματικότητα των υβριδικών προσεγγίσεων. Το DeepMedic και το ViT παρουσιάζουν διαφορετικά πλεονεκτήματα. Συγκεκριμένα το ViT επιδεικνύει υψηλό precision και sensitivity παρά τον χαμηλότερο δείκτη Dice. Αυτό υποδεικνύει την ανάγκη για περισσότερα δεδομένα εκπαίδευσης ως προς τα μοντέλα που βασίζονται σε Transformers. Αξιοσημείωτο είναι ότι όλα τα μοντέλα επιτυγχάνουν αξιόλογες επιδόσεις παρά την απουσία τεχνικών επαύξησης δεδομένων, αποδεικνύοντας την ισχυρή βάση των σύγχρονων αρχιτεκτονικών βαθιάς μάθησης στην τρισδιάστατη τμηματοποίηση.

5 Συζήτηση

Σε αυτό το κεφάλαιο αναλύονται και ερμηνεύονται τα ευρήματα της πειραματικής αξιολόγησης που παρουσιάστηκαν στο κεφάλαιο των αποτελεσμάτων. Εδώ εξετάζονται λεπτομερώς τα δυνατά και αδύναμα σημεία των επιλεγμένων μοντέλων για την τρισδιάστατη τμηματοποίηση εγκεφαλικών όγκων, αξιολογείται η αποτελεσματικότητά τους όσον αφορά την ακρίβεια, τη γενίκευση και την ενσωμάτωσή τους σε κλινικά περιβάλλοντα, και τελικά συζητούνται οι επιπτώσεις των παρατηρήσεων αυτών στην πρακτική εφαρμογή της τεχνητής νοημοσύνης στην ιατρική διάγνωση.

Η συζήτηση εστιάζει στις επιδόσεις των μοντέλων. Επιπλέον, αναλύονται οι περιορισμοί που παρατηρήθηκαν κατά τη διάρκεια των πειραμάτων, όπως η υπολογιστική πολυπλοκότητα και η ανάγκη για περαιτέρω βελτιστοποίηση των μοντέλων, και τίθενται ερωτήματα σχετικά με την γενίκευση των αποτελεσμάτων σε διαφορετικά κλινικά περιβάλλοντα .

Η παρούσα ανάλυση συμβάλλει στη διαμόρφωση μιας ολοκληρωμένης εικόνας για το πώς οι προσεγγίσεις αυτές μπορούν να βελτιωθούν και να ενσωματωθούν αποτελεσματικά στην κλινική πρακτική, προτείνοντας μελλοντικές κατευθύνσεις για έρευνα που θα επιδιώξει την αντιμετώπιση των υφιστάμενων προκλήσεων και την επέκταση των δυνατοτήτων των συστημάτων ΑΙ στην ιατρική απεικόνιση.

5.1 Ανάλυση των Ευρημάτων

Τα αποτελέσματα της μελέτης επιβεβαιώνουν την ικανότητα των αρχιτεκτονικών τύπου U-Net και των υβριδικών μοντέλων με μετασχηματιστές να επιτυγχάνουν υψηλή ακρίβεια τμηματοποίησης. Τα μοντέλα που ενσωματώνουν μετασχηματιστές, ειδικότερα, επέδειξαν βελτιωμένη απόδοση στην αναγνώριση και οριοθέτηση πολύπλοκων περιοχών όγκων, χάρη στην ικανότητά τους να αναλύουν μακροχρόνιες εξαρτήσεις μεταξύ voxel. Η παρατήρηση αυτή συμβαδίζει με τις πρόσφατες έρευνες, που δείχνουν ότι οι transformers είναι ιδιαίτερα κατάλληλοι για εφαρμογές με μεγάλο όγκο δεδομένων, λόγω της δυνατότητάς τους να επεξεργάζονται αποτελεσματικά πολύπλοκες δομές.

Επιπλέον, η συγκριτική αξιολόγηση κατέδειξε ότι οι τεχνικές προεπεξεργασίας των δεδομένων είχαν ουσιώδη επίδραση στην απόδοση όλων των μοντέλων, επιβεβαιώνοντας τη σημασία της ποιότητας των δεδομένων εισόδου για την επιτυχή εκπαίδευση και αξιολόγηση των δικτύων. Ιδιαίτερα, οι τεχνικές κανονικοποίησης και καθαρισμού δεδομένων οδήγησαν σε βελτίωση των αποτελεσμάτων, καθώς μείωσαν τον θόρυβο και τις αποκλίσεις στα δεδομένα εκπαίδευσης, κάτι που συνεισέφερε στην καλύτερη γενίκευση των μοντέλων. Τέλος, αξίζει να σημειωθεί ότι ακόμη και μικρές διαφορές στην επιλογή των υπερπαραμέτρων είχαν σημαντική επίδραση στην απόδοση, υπογραμμίζοντας την ανάγκη για προσεκτική επιλογή και βελτιστοποίηση τους κατά τη διαδικασία εκπαίδευσης.

5.2 Περιορισμοί της Μελέτης

Παρά τα ενθαρρυντικά αποτελέσματα, η εργασία παρουσιάζει ορισμένους περιορισμούς που πρέπει να αναφερθούν και να αναλυθούν περαιτέρω. Πρώτον, το γεγονός ότι δεν αξιοποιήθηκαν τεχνικές επαύξησης δεδομένων περιόρισε τη γενίκευση και την ανθεκτικότητα των μοντέλων, ιδίως σε πραγματικά, ετερογενή κλινικά δεδομένα. Η έλλειψη επαύξησης δεδομένων ενδεχομένως οδήγησε σε μια περιορισμένη ικανότητα των μοντέλων να προσαρμοστούν σε διαφορετικές και απροσδόκητες καταστάσεις, γεγονός που μειώνει την αξιοπιστία τους σε πρακτικές εφαρμογές.

Επιπλέον, η απουσία εφαρμογής μεθόδων ερμηνευσιμότητας, όπως το Grad-CAM, στερεί από τη μελέτη τη δυνατότητα βαθύτερης κατανόησης των αποφάσεων των μοντέλων, γεγονός που είναι κρίσιμο για την κλινική αποδοχή και αξιοποίηση αυτών των εργαλείων. Η ερμηνευσιμότητα είναι απαραίτητη προκειμένου οι ιατροί να μπορούν να εμπιστευτούν τις αποφάσεις του συστήματος και να κατανοήσουν γιατί συγκεκριμένες περιοχές εντοπίστηκαν ως παθολογικές. Η μελλοντική έρευνα θα πρέπει να δώσει ιδιαίτερη έμφαση στην εφαρμογή τέτοιων τεχνικών, ώστε να ενισχυθεί η κλινική εγκυρότητα και η διαφάνεια των αποτελεσμάτων.

Τέλος, ένας ακόμη περιορισμός αφορά το σύνολο δεδομένων BraTS, το οποίο, αν και ευρέως χρησιμοποιούμενο και καλά δομημένο, ενδέχεται να μην αντιπροσωπεύει πλήρως την ποικιλότητα των πραγματικών κλινικών δεδομένων. Αυτό μπορεί να οδηγήσει σε υπερεκτίμηση της απόδοσης των μοντέλων σε ένα πιο ελεγχόμενο περιβάλλον, και να απαιτείται περαιτέρω έλεγχος και επικύρωση με μεγαλύτερη ποικιλία κλινικών δεδομένων.

5.3 Κλινική Σημασία των Αποτελεσμάτων

Η υψηλή απόδοση των αρχιτεκτονικών βαθιάς μάθησης που εξετάστηκαν υπογραμμίζει τη δυνατότητα αξιοποίησής τους ως βοηθητικά εργαλεία στην κλινική πρακτική, ιδιαίτερα στη διάγνωση και θεραπεία εγκεφαλικών όγκων. Η ικανότητα ακριβούς τμηματοποίησης προσφέρει σημαντικά πλεονεκτήματα στη χειρουργική επέμβαση, επιτρέποντας πιο ακριβή και λιγότερο επεμβατική προσέγγιση. Επιπλέον, στη ακτινοθεραπεία, η δυνατότητα λεπτομερούς τμηματοποίησης συμβάλλει στον καλύτερο σχεδιασμό των θεραπευτικών πλάνων, μειώνοντας την έκθεση υγιών ιστών σε ακτινοβολία.

Επιπρόσθετα, η χρήση τέτοιων μοντέλων στην παρακολούθηση της εξέλιξης της νόσου επιτρέπει μια πιο αντικειμενική και επαναλαμβανόμενη αξιολόγηση της θεραπευτικής αποτελεσματικότητας, κάτι που ενισχύει την εξατομικευμένη προσέγγιση στη διαχείριση των ασθενών. Συνεπώς, τα αποτελέσματα αυτά δείχνουν ότι η ενσωμάτωση προηγμένων τεχνικών βαθιάς μάθησης στην κλινική πρακτική μπορεί να οδηγήσει σε βελτιωμένη διάγνωση και θεραπεία, με θετικό αντίκτυπο στην ποιότητα ζωής και την επιβίωση των ασθενών.

Τέλος, η εργασία παρέχει ένα χρήσιμο σημείο αναφοράς για τη μελλοντική έρευνα, προτείνοντας την περαιτέρω ενσωμάτωση τεχνικών επαύξησης δεδομένων και μεθοδολογιών ερμηνευσιμότητας, ώστε να επιτευχθεί μεγαλύτερη κλινική αξιοπιστία και διαφάνεια.

6 Συμπεράσματα

Η παρούσα εργασία εστιάστηκε στη διερεύνηση της τρισδιάστατης τμηματοποίησης εγκεφαλικών όγκων με τη χρήση σύγχρονων μοντέλων βαθιάς μάθησης, εστιάζοντας ειδικά στην εφαρμογή των εν λόγω μοντέλων σε μη επεξεργασμένα δεδομένα (χωρίς προεπεξεργασία ή επαύξηση). Παρά τις συνηθισμένες πρακτικές βελτίωσης της ποιότητας των δεδομένων (π.χ. θορυβομείωση, κανονικοποίηση, γεωμετρικές ή φασματικές μετατροπές), η επιλογή μη εφαρμογής τους προσέφερε την ευκαιρία να αποτιμηθεί η «απλή», εκ του συστήματος, αποδοτικότητα των αρχιτεκτονικών σε πραγματικές συνθήκες, όπου το αρχικό υλικό ενδέχεται να είναι ανομοιογενές ή ανεπαρκώς επιμελημένο.

Από τη βιβλιογραφική ανασκόπηση (Κεφάλαιο 2) αναδείχθηκε η κλινική σημασία της ακριβούς τρισδιάστατης τμηματοποίησης, τόσο για τη διάγνωση και την παρακολούθηση εγκεφαλικών νεοπλασιών όσο και για την εξατομίκευση της θεραπευτικής προσέγγισης. Επιπλέον, τονίστηκε η αυξανόμενη τάση χρήσης υβριδικών αρχιτεκτονικών (CNNs σε συνδυασμό με Μετασχηματιστές) και υπογραμμίστηκαν οι κρίσιμες προκλήσεις: η εξασφάλιση ικανοποιητικής ακρίβειας και γενίκευσης, τα νομικά/ηθικά θέματα που σχετίζονται με ευαίσθητα ιατρικά δεδομένα και η ανάγκη για ερμηνευσιμότητα των μοντέλων.

Η μεθοδολογία που παρουσιάστηκε (Κεφάλαιο 3) περιλάμβανε τη χρήση δεδομένων από δημόσια διαθέσιμα σύνολα (π.χ. BraTS), με στόχο να δοκιμαστεί η απόδοση τεσσάρων επιλεγμένων τρισδιάστατων δικτύων σε μη επεξεργασμένο υλικό. Επιλέχθηκε να μη γίνει προεπεξεργασία (π.χ. εξομάλυνση θορύβου, τυποποίηση εντάσεων) ούτε επαύξηση (data augmentation), έτσι ώστε να εκτιμηθεί η εγγενής ικανότητα των μοντέλων να διαχειρίζονται θορυβώδη ή ετερογενή δεδομένα. Παράλληλα, διευκολύνθηκε η απλότητα του πειραματικού πρωτοκόλλου, με στόχο την ανάδειξη των “καθαρών” επιδόσεων χωρίς περαιτέρω χειρισμούς των δεδομένων.

Στα αποτελέσματα (Κεφάλαιο 4) διαπιστώθηκε ότι, παρά την έλλειψη κάποιας μορφής φιλτραρίσματος ή γεωμετρικού μετασχηματισμού, ορισμένες από τις υπό εξέταση αρχιτεκτονικές επέδειξαν αξιόλογη ανθεκτικότητα· αυτό υπογραμμίζει την ωριμότητα συγκεκριμένων μοντέλων βαθιάς μάθησης που μπορούν να «αντέξουν» σε μη ιδανικό περιβάλλον απεικονίσεων. Ωστόσο, η σύγκριση με άλλες βιβλιογραφικές εργασίες κα-

θιστά σαφές ότι η έλλειψη προεπεξεργασίας μπορεί να στερήσει από τα μοντέλα την πιο ακριβή και λεία πρόβλεψη των ορίων του όγκου, καθώς οι διαφοροποιήσεις στην κλίμακα φωτεινότητας ή στις ακολουθίες MRI συχνά επηρεάζουν αρνητικά την απόδοση.

Στη συζήτηση (Κεφάλαιο 5), τονίστηκε η σημασία της διαφάνειας και της ερμηνευσιμότητας σε ιατρικά περιβάλλοντα, καθώς και ο ρόλος που μπορούν να διαδραματίσουν μέθοδοι εξήγησης (π.χ. Grad-CAM) στην εμπέδωση εμπιστοσύνης από τους κλινικούς ιατρούς. Συνοψίζοντας, η έρευνα κατέδειξε ότι:

- Η τρισδιάστατη τμηματοποίηση επιτυγχάνεται σε ικανοποιητικό βαθμό ακόμη και με ακατέργαστα δεδομένα, επιβεβαιώνοντας την ανθεκτικότητα ορισμένων δικτύων.
- Η απουσία προεπεξεργασίας/επαύξησης μπορεί να απλοποιεί τη ροή εργασίας, αλλά υπογραμμίζει περισσότερα αδυναμικά σημεία των μοντέλων, ιδίως σε μη τυποποιημένες σαρώσεις.
- Η περαιτέρω αναβάθμιση των μοντέλων – για παράδειγμα, μέσω ενσωμάτωσης πιο εξελιγμένων αρχιτεκτονικών ή τεχνικών ερμηνευσιμότητας – διατηρεί ιδιαίτερο ενδιαφέρον, αφού η μελλοντική υιοθέτηση στα νοσοκομεία προϋποθέτει συνδυασμό ακρίβειας, διαφάνειας και φιλικότητας προς τον κλινικό χρήστη.

Η συνέχιση της έρευνας θα μπορούσε να περιλαμβάνει αφενός την ενσωμάτωση βασικών προεπεξεργαστικών σταδίων και αφετέρου την αξιοποίηση αυτόματων τεχνικών επαύξησης, για να διαπιστωθεί πόσο βελτιώνουν τα αποτελέσματα σε σύγκριση με την προσέγγιση “raw data.” Επιπλέον, η έμφαση στην ερμηνευσιμότητα (XAI) και στη γενίκευση των μοντέλων (με νέες μορφές αυτοεποπτευόμενης μάθησης) αποτελεί βασικό στόχο για να διασφαλιστεί η ασφαλής και αποτελεσματική χρήση της τεχνητής νοημοσύνης στην κλινική πρακτική.

Βιβλιογραφία

- [1] M. Cè et al., “Artificial Intelligence in Brain Tumor Imaging: A Step toward Personalized Medicine,” *Current Oncology*, vol. 30, no. 3, pp. 2673–2701, Feb. 2023, doi: 10.3390/curroncol30030203.
- [2] S. Khalighi, K. Reddy, A. Midya, K. B. Pandav, A. Madabhushi, and M. Abedalthagafi, “Artificial intelligence in neuro-oncology: advances and challenges in brain tumor diagnosis, prognosis, and precision treatment,” *npj Precis. Onc.*, vol. 8, no. 1, p. 80, Mar. 2024, doi: 10.1038/s41698-024-00575-0.
- [3] R. Kaifi, “A Review of Recent Advances in Brain Tumor Diagnosis Based on AI-Based Classification // CHAPTER 2.1,” *Diagnostics*, vol. 13, no. 18, p. 3007, Sep. 2023, doi: 10.3390/diagnostics13183007.
- [4] M. A. Kirkman, B. H. M. Hunn, M. S. C. Thomas, and A. K. Tolmie, “Influences on cognitive outcomes in adult patients with gliomas: A systematic review // CHAPTER 2.1,” *Front. Oncol.*, vol. 12, p. 943600, Aug. 2022, doi: 10.3389/fonc.2022.943600.
- [5] R. Mehrotra, M. A. Ansari, R. Agrawal, and R. S. Anand, “A Transfer Learning approach for AI-based classification of brain tumors // CHAPTER 2.1,” *Machine Learning with Applications*, vol. 2, p. 100003, 2020, doi: 10.1016/j.mlwa.2020.100003.
- [6] E. J. Topol, “High-performance medicine: the convergence of human and artificial intelligence,” *Nat Med*, vol. 25, no. 1, pp. 44–56, 2019, doi: 10.1038/s41591-018-0300-7.
- [7] H. Hah and D. S. Goldin, “How Clinicians Perceive Artificial Intelligence–Assisted Technologies in Diagnostic Decision Making: Mixed Methods Approach (Preprint),” Sep. 11, 2021, *Journal of Medical Internet Research*. doi: 10.2196/preprints.33540.
- [8] A. T. Young, D. Amara, A. Bhattacharya, and M. L. Wei, “Patient and general public attitudes towards clinical artificial intelligence: a mixed methods systematic review,” *The Lancet Digital Health*, vol. 3, no. 9, pp. e599–e611, Sep. 2021, doi: 10.1016/S2589-7500(21)00132-1.
- [9] T. Davenport and R. Kalakota, “The potential for artificial intelligence in health-care,” *Future Healthcare Journal*, vol. 6, no. 2, p. 94, Jun. 2019, doi: 10.7861/futurehosp.6-2-94.
- [10] S. Khalighi, K. Reddy, A. Midya, K. B. Pandav, A. Madabhushi, and M. Abedalthagafi, “Artificial intelligence in neuro-oncology: advances and challenges in brain tumor diagnosis, prognosis, and precision treatment,” *npj Precis. Onc.*, vol. 8, no. 1, p. 80, Mar. 2024, doi: 10.1038/s41698-024-00575-0.

- [11] A. Hosny, C. Parmar, J. Quackenbush, L. H. Schwartz, and H. J. W. L. Aerts, “Artificial intelligence in radiology,” *Nat Rev Cancer*, vol. 18, no. 8, pp. 500–510, 2018, doi: 10.1038/s41568-018-0016-5.
- [12] O. S. Pianykh et al., “Continuous Learning AI in Radiology: Implementation Principles and Early Applications,” *Radiology*, vol. 297, no. 1, pp. 6–14, 2020, doi: 10.1148/radiol.2020200038.
- [13] M. Sollini, L. Antunovic, A. Chiti, and M. Kirienko, “Towards clinical application of image mining: a systematic review on artificial intelligence and radiomics,” *Eur J Nucl Med Mol Imaging*, vol. 46, no. 13, pp. 2656–2672, 2019, doi: 10.1007/s00259-019-04372-x.
- [14] H. R. Saeidnia, S. G. Hashemi Fotami, B. Lund, and N. Ghiasi, “Ethical Considerations in Artificial Intelligence Interventions for Mental Health and Well-Being: Ensuring Responsible Implementation and Impact,” *Social Sciences*, vol. 13, no. 7, p. 381, Jul. 2024, doi: 10.3390/socsci13070381.
- [15] O. Ali, W. Abdelbaki, A. Shrestha, E. Elbasi, M. A. A. Alryalat, and Y. K. Dwivedi, “A systematic literature review of artificial intelligence in the healthcare sector: Benefits, challenges, methodologies, and functionalities,” *Journal of Innovation & Knowledge*, vol. 8, no. 1, p. 100333, 2023, doi: 10.1016/j.jik.2023.100333.
- [16] P. Mlynarski, H. Delingette, A. Criminisi, and N. Ayache, “3D Convolutional Neural Networks for Tumor Segmentation using Long-range 2D Context,” Jul. 23, 2018, arXiv: arXiv:1807.08599. Accessed: Oct. 27, 2024. [Online]. Available: <http://arxiv.org/abs/1807.08599>
- [17] K. Kamnitsas et al., “Efficient multi-scale 3D CNN with fully connected CRF for accurate brain lesion segmentation,” *Medical Image Analysis*, vol. 36, pp. 61–78, 2017, doi: 10.1016/j.media.2016.10.004.
- [18] L. Chen, Y. Wu, A. M. DSouza, A. Z. Abidin, A. Wismuller, and C. Xu, “MRI Tumor Segmentation with Densely Connected 3D CNN,” Feb. 09, 2018, arXiv: arXiv:1802.02427. doi: 10.48550/arXiv.1802.02427.
- [19] S. Lakare, “3D Segmentation Techniques for Medical Volumes”.
- [20] R. A. Zeineldin, M. E. Karar, O. Burgert, and F. Mathis-Ullrich, “Multimodal CNN Networks for Brain Tumor Segmentation in MRI: A BraTS 2022 Challenge Solution,” Dec. 19, 2022, arXiv: arXiv:2212.09310. doi: 10.48550/arXiv.2212.09310.
- [21] A. Vaswani et al., “Attention Is All You Need,” Aug. 02, 2023, arXiv: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.
- [22] Z. Liu et al., “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows,” in 2021 IEEE/CVF International Conference on Computer Vision (ICCV), Montreal, QC, Canada: IEEE, 2021, pp. 9992–10002. doi: 10.1109/ICCV48922.2021.00986.
- [23] D. L. Pham, C. Xu, and J. L. Prince, “Current Methods in Medical Image Segmentation,” *Annu. Rev. Biomed. Eng.*, vol. 2, no. 1, pp. 315–337, 2000, doi: 10.1146/annurev.bioeng.2.1.315.

- [24] J. E. Iglesias and M. R. Sabuncu, “Multi-Atlas Segmentation of Biomedical Images: A Survey,” *Medical image analysis*, vol. 24, no. 1, p. 205, Jul. 2015, doi: 10.1016/j.media.2015.06.012.
- [25] A. Hatamizadeh et al., “UNETR: Transformers for 3D Medical Image Segmentation,” Oct. 09, 2021, arXiv: arXiv:2103.10504. doi: 10.48550/arXiv.2103.10504.
- [26] A. Klein et al., “Evaluation of 14 nonlinear deformation algorithms applied to human brain MRI registration,” *NeuroImage*, vol. 46, no. 3, p. 786, Jan. 2009, doi: 10.1016/j.neuroimage.2008.12.037.
- [27] M. Kass, A. Witkin, and D. Terzopoulos, “Snakes: Active contour models,” *Int J Comput Vision*, vol. 1, no. 4, pp. 321–331, 1988, doi: 10.1007/BF00133570.
- [28] Y. Y. Boykov and M.-P. Jolly, “Interactive graph cuts for optimal boundary & region segmentation of objects in N-D images,” in *Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001*, Vancouver, BC, Canada: IEEE Comput. Soc, 2001, pp. 105–112. doi: 10.1109/ICCV.2001.937505.
- [29] H. Cao et al., “Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation,” May 12, 2021, arXiv: arXiv:2105.05537. doi: 10.48550/arXiv.2105.05537.
- [30] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, and K. H. Maier-Hein, “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation,” *Nat Methods*, vol. 18, no. 2, pp. 203–211, 2021, doi: 10.1038/s41592-020-01008-z.
- [31] W. Xin Weihao and Zhu, “Learning Representations by Maximizing Mutual Information Across Views for Medical Image Segmentation,” *MICCAI 2024 - Open Access*. Accessed: Dec. 11, 2024. [Online]. Available: <https://papers.miccai.org/miccai-2024/451-Paper0103>
- [32] “(PDF) Models Genesis,” *ResearchGate*, Dec. 2024, doi: 10.1016/j.media.2020.101840.
- [33] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, and O. Ronneberger, “3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation,” Jun. 21, 2016, arXiv: arXiv:1606.06650. doi: 10.48550/arXiv.1606.06650.
- [34] W. Wang, C. Chen, M. Ding, J. Li, H. Yu, and S. Zha, “TransBTS: Multimodal Brain Tumor Segmentation Using Transformer,” Jun. 26, 2021, arXiv: arXiv:2103.04430. doi: 10.48550/arXiv.2103.04430.
- [35] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation,” Jun. 15, 2016, arXiv: arXiv:1606.04797. doi: 10.48550/arXiv.1606.04797.
- [36] J. Dolz, K. Gopinath, J. Yuan, H. Lombaert, C. Desrosiers, and I. B. Ayed, “HyperDense-Net: A hyper-densely connected CNN for multi-modal image segmentation,” Mar. 02, 2019, arXiv: arXiv:1804.02967. doi: 10.48550/arXiv.1804.02967.
- [37] Y. Zhang et al., “mmFormer: Multimodal Medical Transformer for Incomplete Multimodal Learning of Brain Tumor Segmentation,” Aug. 04, 2022, arXiv: arXiv:2206.02425. doi: 10.48550/arXiv.2206.02425.

- [38] Y. Xie, J. Zhang, C. Shen, and Y. Xia, “CoTr: Efficiently Bridging CNN and Transformer for 3D Medical Image Segmentation,” Mar. 04, 2021, arXiv: arXiv:2103.03024. doi: 10.48550/arXiv.2103.03024.
- [39] H.-Y. Zhou, J. Guo, Y. Zhang, L. Yu, L. Wang, and Y. Yu, “nnFormer: Interleaved Transformer for Volumetric Segmentation,” Feb. 04, 2022, arXiv: arXiv:2109.03201. doi: 10.48550/arXiv.2109.03201.
- [40] H. Chen, Q. Dou, L. Yu, J. Qin, and P.-A. Heng, “VoxResNet: Deep voxelwise residual networks for brain segmentation from 3D MR images,” *NeuroImage*, vol. 170, pp. 446–455, Apr. 2018, doi: 10.1016/j.neuroimage.2017.04.041.
- [41] M. Bilal, G. Ali, M. W. Iqbal, M. Anwar, M. S. A. Malik, and R. A. Kadir, “Auto-Prep: Efficient and Automated Data Preprocessing Pipeline,” *IEEE Access*, vol. 10, pp. 107764–107784, 2022, doi: 10.1109/ACCESS.2022.3198662.
- [42] C. Shorten and T. M. Khoshgoftaar, “A survey on Image Data Augmentation for Deep Learning,” *J Big Data*, vol. 6, no. 1, p. 60, 2019, doi: 10.1186/s40537-019-0197-0.
- [43] L. Zhang and K. Ma, “A Good Data Augmentation Policy is not All You Need: A Multi-Task Learning Perspective,” *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 33, no. 5, pp. 2190–2201, May 2023, doi: 10.1109/TCSVT.2022.3219339.
- [44] J. Lemley, S. Bazrafkan, and P. Corcoran, “Smart Augmentation Learning an Optimal Data Augmentation Strategy,” *IEEE Access*, vol. 5, pp. 5858–5869, 2017, doi: 10.1109/ACCESS.2017.2696121.
- [45] Y. Wang, G. Huang, S. Song, X. Pan, Y. Xia, and C. Wu, “Regularizing Deep Networks with Semantic Data Augmentation,” *IEEE Trans. Pattern Anal. Mach. Intell.*, pp. 1–1, 2021, doi: 10.1109/TPAMI.2021.3052951.
- [46] Z. Liu, “Research on data preprocessing method for artificial intelligence algorithm based on user online behavior,” *JCEIM*, vol. 12, no. 3, pp. 74–78, Apr. 2024, doi: 10.54097/qf6fv8j1.
- [47] B. Bala and S. Behal, “A Brief Survey of Data Preprocessing in Machine Learning and Deep Learning Techniques,” in *2024 8th International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, Oct. 2024, pp. 1755–1762. doi: 10.1109/I-SMAC61858.2024.10714767.
- [48] M. Havaei et al., “Brain Tumor Segmentation with Deep Neural Networks,” *Medical Image Analysis*, vol. 35, pp. 18–31, 2017, doi: 10.1016/j.media.2016.05.004.
- [49] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization,” Dec. 03, 2019, arXiv: arXiv:1610.02391. Accessed: Oct. 31, 2024. [Online]. Available: <http://arxiv.org/abs/1610.02391>
- [50] H. Chen, Q. Dou, L. Yu, J. Qin, and P.-A. Heng, “VoxResNet: Deep voxelwise residual networks for brain segmentation from 3D MR images,” *NeuroImage*, vol. 170, pp. 446–455, 2018, doi: 10.1016/j.neuroimage.2017.04.041.

- [51] A. Dosovitskiy et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” Jun. 03, 2021, arXiv: arXiv:2010.11929. Accessed: Oct. 16, 2024. [Online]. Available: <http://arxiv.org/abs/2010.11929>
- [52] H. Zhang and K. Ogasawara, “Grad-CAM-Based Explainable Artificial Intelligence Related to Medical Text Processing,” *Bioengineering*, vol. 10, no. 9, p. 1070, Sep. 2023, doi: 10.3390/bioengineering10091070.
- [53] S. Suara, A. Jha, P. Sinha, and A. A. Sekh, “Is Grad-CAM Explainable in Medical Images?,” Jul. 20, 2023, arXiv. doi: 10.48550/arXiv.2307.10506.
- [54] N. Barr Kumarakulasinghe, T. Blomberg, J. Liu, A. Saraiva Leao, and P. Papapetrou, “Evaluating Local Interpretable Model-Agnostic Explanations on Clinical Machine Learning Classification Models,” in 2020 IEEE 33rd International Symposium on Computer-Based Medical Systems (CBMS), Jul. 2020, pp. 7–12. doi: 10.1109/CBMS49503.2020.00009.
- [55] L. Alzubaidi et al., “Review of deep learning: concepts, CNN architectures, challenges, applications, future directions,” *J Big Data*, vol. 8, no. 1, pp. 1–74, Dec. 2021, doi: 10.1186/s40537-021-00444-8.
- [56] M. Sundararajan, A. Taly, and Q. Yan, “Axiomatic Attribution for Deep Networks,” Jun. 13, 2017, arXiv: arXiv:1703.01365. doi: 10.48550/arXiv.1703.01365.
- [57] S. Suara, A. Jha, P. Sinha, and A. A. Sekh, “Is Grad-CAM Explainable in Medical Images?,” Jul. 20, 2023, arXiv: arXiv:2307.10506. doi: 10.48550/arXiv.2307.10506.
- [58] E. Tjoa and C. Guan, “A Survey on Explainable Artificial Intelligence (XAI): Towards Medical XAI,” *IEEE Trans. Neural Netw. Learning Syst.*, vol. 32, no. 11, pp. 4793–4813, 2021, doi: 10.1109/TNNLS.2020.3027314.
- [59] P. J. Phillips et al., “Four principles of explainable artificial intelligence,” National Institute of Standards and Technology (U.S.), Gaithersburg, MD, NIST IR 8312, Sep. 2021. doi: 10.6028/NIST.IR.8312.
- [60] W. Wang, C. Chen, M. Ding, J. Li, H. Yu, and S. Zha, “TransBTS: Multimodal Brain Tumor Segmentation Using Transformer,” Jun. 26, 2021, arXiv: arXiv:2103.04430. doi: 10.48550/arXiv.2103.04430.
- [61] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” May 18, 2015, arXiv: arXiv:1505.04597. doi: 10.48550/arXiv.1505.04597.
- [62] A. Dosovitskiy et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” Jun. 03, 2021, arXiv: arXiv:2010.11929. doi: 10.48550/arXiv.2010.11929.